

Quentin Lobbé

Archives et Fragments Web

Désagréger les archives Web pour mener une exploration temporelle de traces numériques des migrations

Université Paris-Saclay, École doctorale des sciences et technologies de l'information et de la communication.
Thèse pour l'obtention du doctorat de Télécom ParisTech et de l'Université Paris-Saclay.

Thèse présentée par **Quentin Lobbé**

LTCI, Télécom ParisTech, Université Paris Saclay & Inria. Paris, France.

quentin.lobbe@telecom-paristech.fr

Sous la direction de :

Pierre Senellart, professeur à l'École Normale Supérieure

Dana Diminescu, professeure à Télécom ParisTech

Soutenue publiquement à Paris le 9 novembre 2018, devant un jury composé de :

Bruno Bachimont (Rapporteur), enseignant-chercheur à l'Université Technologique de Compiègne

Marc Spaniol (Rapporteur), professeur à l'Université de Caen Basse-Normandie

Anat Ben-David, professeure à l'Open University of Israel

Dominique Cardon, professeur associé à Sciences Po Paris

Bruno Defude, directeur adjoint de la recherche et des formations doctorales à Télécom SudParis

last modified May 2018

Il me demanda de chercher la première page.

Je posais ma main gauche sur la couverture et ouvris le volume de mon pouce serré contre l'index. Je m'efforçais en vain : il restait toujours des feuilles entre la couverture et mon pouce. Elles semblaient sourdre du livre.

- Maintenant cherchez la dernière.

Mes tentatives échouèrent de même; à peine pus-je balbutier d'une voix qui n'était plus ma voix :

- Cela n'est pas possible.

Toujours à voix basse le vendeur me dit :

- Cela n'est pas possible et pourtant cela *est*. Le nombre de pages de ce livre est exactement infini. Aucune n'est la première, aucune n'est la dernière.

Jorge Luis Borges - Le livre de sable

| Remerciements

Ici je remercie plein de gens
Beaucoup de gens
Mais vraiment

| Table des matières

Chapitre 1	Introduction	13
1.1	<i>Introduction générale</i>	13
1.2	<i>Mise en garde</i>	13
Chapitre 2	Du Web aux Représentations en Ligne des Diasporas	15
2.1	<i>Retour aux origines du Web</i>	15
2.2	<i>Le migrant connecté</i>	15
2.3	<i>Le Web, espace de communication et d'organisation</i>	15
2.4	<i>L'Atlas e-Diasporas</i>	15
Chapitre 3	20 ans d'archivage du Web	17
3.1	<i>Les pionniers</i>	17
3.2	<i>Préserver notre héritage numérique</i>	17
3.3	<i>Constituer des corpus d'archives</i>	17
3.4	<i>Les archives Web de l'Atlas e-Diasporas</i>	17
Chapitre 4	Traces Discrétisées et Temporalité Figée	19
4.1	<i>Détruire pour mieux archiver</i>	19
4.2	<i>Un temps sans extension</i>	19
4.3	<i>Construire un moteur d'exploration d'archive</i>	20
4.4	<i>Les archives sont des traces indirectes du Web</i>	20
Chapitre 5	Fragmenter les Archives Web	21
5.1	<i>Vers une nouvelle unité d'exploration</i>	22

	5.2 <i>Le fragment Web : définition</i>	
	5.3 <i>Scraping et méthodologie d'extraction</i>	28
	5.4 <i>Penser une exploration désagrégée</i>	28
	5.5 <i>Intégration à un moteur d'exploration</i>	28
Chapitre 6	Explorations de Collectifs Migrants Éteints	29
	6.1 <i>À la recherche de l'étonnement : l'analyse exploratoire de données</i>	29
	6.2 <i>Les traces d'une mutation numérique</i>	29
	6.3 <i>Un soulèvement en ligne éphémère</i>	30
	6.4 <i>Les Moments Pivot du Web</i>	31
Chapitre 7	Au Delà Des Archives Web	33
	7.1 <i>Remettre l'humain au cœur des archives</i>	33
	7.2 <i>Fouiller les archives du Web profond</i>	33
	7.3 <i>Les traces nativement numérique</i>	33
	7.4 <i>Vers une sociologie numérique des migrations</i>	33
Chapitre 8	Ressources	35
	8.1 <i>References</i>	35
	8.2 <i>Figures and Tables</i>	35
Chapitre 9	Conclusion	37
Chapitre	Bibliographie	39

| List of Figures

- 4.1 Warc vs Daff 19
- 5.1 Extraits de "*Je Vous Salue, Sarajevo*", J.L. Godard (1993) à partir d'une photographie de R. Haviv (1992) 23
- 5.2 Les 5 strates analytiques du Web, d'après (Brügger, 2009) 25
- 8.1 This is a margin figure. The helix is defined by $x = \cos(2\pi z)$, $y = \sin(2\pi z)$, and $z = [0, 2.7]$. The figure was drawn using Asymptote (<http://asymptote.sf.net/>). 35
- 8.2 This graph shows $y = \sin x$ from about $x = [-10, 10]$. *Notice that this figure takes up the full page width.* 36
- 8.3 Hilbert curves of various degrees n . 36

| List of Tables

Chapitre 1

| Introduction

1.1 Introduction générale

Ici l'intro de la thèse.

1.2 Mise en garde

Penser le passé depuis le présent

Ici on fait un rapide détour par l'historiographie et les difficultés à parler du passé depuis le présent.

Conservation différentielle et nature des archives Web

Ici on parle de la raréfaction de la matière Web à mesure que l'on remonte le temps et également à mesure que le web fournit du contenu.

Chapitre 2

| Du Web aux Représentations en Ligne des Diasporas

2.1 Retour aux origines du Web

2.2 Le migrant connecté

2.3 Le Web, espace de communication et d'organisation

2.4 L'Atlas e-Diasporas

Chapitre 3

| 20 ans d'archivage du Web

3.1 Les pionniers

Internet Archive et le pre-Unesco

3.2 Préserver notre héritage numérique

L'unesco et faire des archives un commun Un tour du monde des initiatives La constitution juridique des corpus en france Et l'état de l'archivage aujourd'hui (fin de Internet memory et les rogues archivistes)

3.3 Constituer des corpus d'archives

Méthodologie d'acquisition

Où l'on fait le tour de l'état de l'art en matière de création d'archives Web, de crawl, etc ...

le web n'est plus le web (brugger) le web s'archive lui même et l'archive ne capture que le front end

Un format unique ?

Où l'on parle du WARC (et de ces prédécesseurs) vs le DAFF

3.4 Les archives Web de l'Atlas e-Diasporas

Présentation rapide de l'ensemble des corpus et focus sur les Marocains (explication ...)

| Traces Discrétisées et Temporalité Figée

4.1 Détruire pour mieux archiver

De Derrida aux traces discrétisées, de la sélection effectuée par le crawler et l'archiviste, les archives sont des traces discrètes du Web, comme Funes on ne peut tout garder

4.2 Un temps sans extension

Ici on part de Saint Augustin et de sa définition d'un présent sans extension qui a influencé le rapport des occidentaux au temps. Ce rapport au temps se retrouve lorsque l'on étudie en détail les modèles d'exploration des archives web qui s'appuient sur la date de capture d'un contenu. S'en suivent plusieurs remarques qu'il faut conserver en tête avant de se plonger dans toute exploration

Crawl blindness

Cohérence

Duplicata

4.3 Construire un moteur d'exploration d'archive

Extraction et enrichissement

Définition du schéma d'indexation

Détection d'événements

4.4 Les archives sont des traces indirectes du Web

Les archives sont les traces directes du crawler et non du web (Cf mises en gardes précédentes) + exemple sur yabiladi.com donc il faut descendre au niveau de la page et y extraire d'autres temporalités, d'autres forme d'exploration qui ne dépendent pas non plus de la linéarité proposé par les moteurs d'exploration classique. La désagregation se fait dans le modèle de données mais également dans la façon de conduire sont exploration.

| Fragmenter les Archives Web

Les effets de crawl legacy (Section 4.4) sont indissociables des archives Web telles que nous les connaissons. Liés organiquement à la structure même des fichiers archivés (Figure 4.1), ils en sont les artéfacts directs. Pour qui souhaite conduire l'analyse d'un ensemble de sites Web archivés, ces effets induisent nombres d'obstacles : collectage non régulier, sur-représentation de certaines parties d'un site, incohérences entre contenus archivés, etc. Lors de la consultation des archives, l'explorateur n'a que très rarement la main sur les commandes du crawler et doit se contenter de l'état du corpus qui lui est proposé.

Nos travaux portant sur l'exploration de corpus d'archives Web déjà existants et/ou constitués de longue date, nous ne proposerons pas ici d'alternative aux formats WARC et DAFF. Nous chercherons plutôt à définir une stratégie d'exploration capable de s'affranchir de l'héritage pesant des crawlers sur les archives Web ou tout au moins d'en atténuer les effets. Il faut également préciser que nous conditionnons notre réflexion à la réalisation d'une exploration large (en terme de pages à visiter) et profonde (en terme de durée à parcourir) des archives Web qui implique le développement d'une méthodologie dédiée à une échelle si large (Chapitre 6). Il va sans dire, que pour l'étude à la main d'une poignée de sites ou de pages (depuis la WayBack Machine par exemple), les effets de crawl legacy restent parfaitement surmontables. En revanche, cette tâche devient rapidement fastidieuse voire titanique à mesure que grandit le périmètre d'exploration et que la validation humaine s'efface au profit d'un algorithme ou d'un ensemble de scripts.

Sur ce point, nous proposerons l'introduction d'une nouvelle unité d'exploration des archives Web : le **fragment Web**. L'essentiel de ce chapitre sera consacré à expliciter l'intuition selon laquelle il peut être bénéfique de descendre au delà du niveau des pages Web archivées en proposant un changement d'échelle analytique. Le fragment Web devra d'une part offrir aux explorateurs du Web passé une plus grande souplesse et de nouveaux outils pour déconstruire, recomposer et questions les archives, et d'autre part, cette unité devra devenir un objet

d'étude à part entière. Plutôt que d'être une trace directe du crawler, le fragment Web cherchera à témoigner des gestes de l'auteur ou du lecteur d'un site archivé dont le passages parmi ses pages aura laissé des indices qu'il nous faudra exploiter. Nous nous concentrerons particulièrement sur la question de la bonne datation d'une page Web archivée en nous basant sur les dates de création et d'édition de tel ou tel contenu. En associant le fragment Web à une date d'édition nous discuterons du changement de temporalité ainsi constaté : passant du crawler à la page Web et ses fragments. Nous en illustrerons ensuite le bénéfice potentiel en terme de précision historique. Enfin, nous reviendrons en miroir sur les modalités techniques et théoriques d'un moteur d'exploration d'archives Web (Chapitre 4) prenant dès à présent le fragment Web comme unité principale d'indexation. Une démonstration en sera donnée via un cas simple de détection d'événements parmi le contenu fragmenté des archives de *yabiladi.com*.

Tout au long de ce chapitre, nous appuierons nos réflexions sur les travaux de l'historien du Web N. Brügger et sur la notion de *strates analytiques du Web* qui servira de cadre à la définition de nos propres fragments Web. La question du changement de temporalité sera, quant à elle, abordée à l'aune des recherches de l'historien médiéviste J. Baschet sur les enjeux historiographiques d'un tel déplacement.

5.1 Vers une nouvelle unité d'exploration

Toute archive est une matière destinée à être désagrégée ou ré-arrangée en vue de la questionner et d'écrire l'histoire. Ainsi le professeur d'archivistique E. Ketelaar dit d'une archive qu'elle ne parle pas seule (Ketelaar, 2006), qu'elle n'est jamais fermée ou complète. Une archive se tient toujours prête à être réinterprétée par une nouvelle génération d'explorateur ou de chercheur. Mais s'il est clair que la direction prise avec l'introduction du fragment Web est celle d'une déconstruction des corpus d'archives Web existants, gardons à l'esprit comme le rappelle Derrida¹, que le document d'origine ne doit en aucun cas être altéré ou modifié. Et ce, pour justement permettre à d'autres, après nous, d'à nouveau s'y référer, le faire parler.

Précisons donc avant toute chose, que le fragment Web, ne sera pas une version modifiée d'une page Web archivée et de ses fichiers sources, mais bien une entité autre, issue du fractionnement de cette page et utilisable en parallèles des modèles d'exploration d'archives déjà existants.

¹ "je peux interroger, contredire, attaquer ou simplement déconstruire une logique du texte venu avant moi, devant moi, mais je ne peux ni ne dois le changer", p.374. (Derrida, 1995)

Découper, déplacer, monter

Nous évoquions déjà dans la section 4.1 le personnage de Funes imaginé par Borges qui, dans la fable, à force de ne plus jamais rien oublier, voyait décroître ses capacités à penser et à raisonner. Funes vit dans l'indexation d'un perpétuel présent. Il se redécouvre sans cesse et n'arrive plus à se recréer des souvenirs, à se raconter de mémoire sa propre histoire².

Pour mémoriser ou archiver il faut oublier. Ré-arranger et faire du montage. Nos souvenirs sont des sélections qui, mises bout à bout, collées, accélérées ou ralenties forment le fil de nos histoires. Le cinéaste C. Marker donne corps à cette idée dans son film d'archives *"Le Fond de l'Air est Rouge"*³ où la posture de l'historien face à un document archivé se rapproche de celle du monteur de cinéma face à une matière filmée. Leurs outils sont semblables. Lorsqu'il invente l'histoire, l'historien découpe, isole et rapproche des sources archivées potentiellement très éloignées.

Dans son court métrage *"Je Vous Salue, Sarajevo"*, réalisé en 1993 pendant la Guerre de Bosnie-Herzégovine⁴, J.L. Godard déconstruit une photographie du reporteur de guerre R. Haviv. Il fragmente et fait se confronter des inserts éclatés à la manière d'un collage-poème ou d'un cinétract⁵. Par le collage, les fondus et les découpes Godard rompt la continuité de l'archive qu'il utilise comme source première afin de rendre compte image après image de la cruauté qui frappe Sarajevo, une ville de son temps (Figure 5.1). Le film finit par dévoiler entière, l'image dans toute son horreur. Décomposer pour mieux recomposer.

² "[Funes], ne l'oublions pas, était presque incapable d'idées générales, platoniques. Son propre visage dans la glace, ses propres mains, le surprenaient chaque fois.", p.??., (Borges, 1974)

³ Film réalisé en 1977. C. Marker superpose par exemple aux souvenirs de S. Signoret des extraits remontés et recolorisés du *"Cuirassé Potemkine"* d'Eisenstein (<https://youtu.be/d01E4GYjF1s>)

⁴ Voir <https://youtu.be/WKbfu8rRrho>

⁵ Mini-films non signés à caractère militant, réalisés en mai et juin 1968 (<https://fr.wikipedia.org/wiki/Cin%C3%A9tract>)



Figure 5.1: Extraits de *"Je Vous Salue, Sarajevo"*, J.L. Godard (1993) à partir d'une photographie de R. Haviv (1992)

Il y a dans les travaux de Godard et de Marker une souplesse d'action vis à des archives à même de se révéler profitable si nous l'appliquions aux archives Web. Chercher à avoir en main des éléments fragmentés de pages Web éloignées, que nous pourrions associer, à souhait, afin de traiter plus largement d'un moment particulier de l'histoire du Web. Comment se donner la possibilité de rapprocher automatiquement deux contenus archivés hors du carcans de leurs pages respectives ? Peut-on par exemple demander à un moteur d'exploration d'archives de nous retourner l'ensemble des messages postés sur un forum, par une seule et même personne il y a dix ans de cela ?

Les strates analytiques du Web

Le glissement d'un niveau d'analyse à un autre, vers un en-dessous de la page archivée, a été une première fois formulée par l'historien du Web N. Brügger (Brügger, 2009) sous la notion de *strates analytiques du Web*⁶. Questionnant la nature même d'un site Web comme potentiel objet de recherches historiques, N. Brügger suggère la possibilité de construire un système dynamique pour réajuster, à souhait, la portée de l'étude d'un site Web à chacun de ses sous-éléments constitutifs⁷. Cette approche, notons-le, n'est pas confinée au Web archivé, elle peut très bien s'adapter au Web vivant. Brügger introduit ainsi 5 niveaux d'analyses (présentés ci-dessous du plus englobant au plus précis):

1. le Web dans son entièreté
2. une sphère Web
3. un site Web
4. une page Web
5. un élément Web

Le premier niveau (Figure 5.2) englobe l'entièreté des sites du Web vivant, leurs dépendances en back-end (bases de données, code, feuilles de style, etc) ainsi que l'ensemble de l'infrastructure physique du Web (serveurs, câbles réseaux, supports numériques, etc). Les sphères Web, inspirées des travaux de S. Foot sur le volet numérique des campagnes électorales états-unienues du début des années 2000 (Foot and Schneider, 2006), désignent des ensembles de sites Web sélectionnés par un chercheur. C'est une construction ad hoc motivée par une question de recherche donnée, une thématique précise. Les acteurs Web regroupés au sein de ces sélections n'ont pas forcément conscience d'appartenir à un tel groupe. À titre d'exemple, les réseaux e-Diasporas (voir Chapitre 2) peuvent être considérés comme des sphères Web. En revanche, une

⁶ En anglais : *analytical Web strata*.

⁷ "One can distinguish the following five analytical strata: the web as a whole; the web sphere; the individual website; the individual webpage; and an individual textual web element on a webpage, such as an image", (Brügger, 2009), p.19

blogosphère dont les acteurs sont parfois à l'origine même de sa construction et de sa promotion⁸ n'est pas strictement équivalente à une sphère Web. Sites et pages Web sont ensuite définis de manière égale à ce que nous proposons au Chapitre 4.

La notion d'élément Web, quant à elle, concrétise l'intuition selon laquelle une analyse du Web devrait également descendre en deçà des pages. L'élément Web est ainsi défini comme l'élément textuel minimal d'une page Web⁹. Ce peut être un ensemble de caractères écrits, des images fixes ou mobiles, ainsi que des sons. Pour Brügger, un élément Web textuel doit être considéré suivant le rapport médium/texte¹⁰ qu'il définit comme composante essentielle de tout artéfact Web. Ce rapport est explicité dans un texte antérieur (Brügger, 2002) comme l'alliance d'une matérialité matérielle du Web (les ordinateurs constitués de pièces de plastique, de métal ou de verre) et d'une matérialité immatérielle du Web (le code informatique¹¹).

⁹ "The Web element is the minimal textual element on a webpage", (Brügger, 2009), p.20.

¹⁰ "the intermediate textual level that the codes of o/1 and their syntax constitute — a level that is in itself a text, insofar as it is composed of letters and a syntax", (Brügger, 2009), p.9.

¹¹ "the energy-based binary alphabet", (Brügger, 2002), p.21.

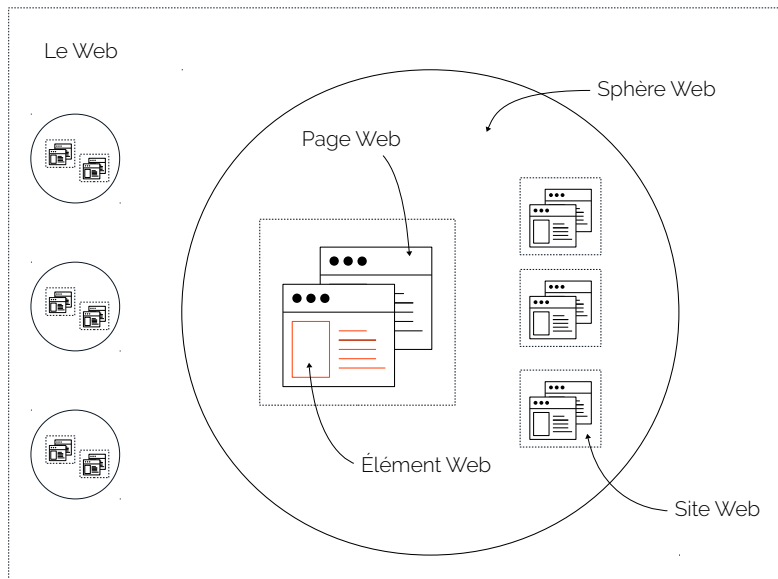


Figure 5.2: Les 5 strates analytiques du Web, d'après (Brügger, 2009)

Notre *fragment Web* pourra assez naturellement s'inscrire dans la continuité des strates analytiques du Web, se situant quelque part entre l'élément Web et la page Web. Mais s'il ne nous semble pas nécessaire de descendre à un tel niveau de différenciation entre matérialité et immatérialité du Web¹² nous tenons tout de même à conserver la séparation entre le back-end du front-end et plus particulièrement la différence entre un élément tel qu'affiché à l'écran depuis le navigateur et la portion de code informatique dont il est l'expression. Le *fragment Web* traduira tout autant une portion de code (HTML, CSS ou JS) et

¹² Rappelons que le Web archivé n'est déjà plus le Web, qu'il n'est que l'enregistrement sur fichier de son front-end. Le back-end n'étant pas archivé.

son interprétation à l'écran.

La question de la datation d'une page archiver

Il nous semble essentiel de séparer les archives Web des liens qui les unissent au crawler afin de redonner à ces dernières leur réalité historique facilement interrogeable à grande échelle. Pour y arriver, il faut tout d'abord résoudre le problème de la datation d'une page archivée.

Comme nous l'avons présenté dans le chapitre 3, les différents formats de fichier d'archives Web sont tous construits à partir des pages Web. Ce sont schématiquement des collections de pages HTML enregistrées sur fichier et associées à une date d'archivage ou aussi appelé date de téléchargement. Dans les moteurs d'explorations d'archive existants, lorsque l'on procède à une recherche, les résultats sont répartis par date de téléchargement même si le contenu archivé a en réalité été créé des années auparavant (Chapitre 4).

Dérrière la question de la datation se cachent l'idée de retrouver les gestes des acteurs qui ont, par leurs actions, contribué à alimenter et faire vivre un site web.

Vue depuis le navigateur, les actions des acteurs sont traduits par des changements sur les pages Web. Or s'il est compliqué pour le moment de définir une date de suppression ou une date de modification d'un contenu donné, la date de création de ces derniers peut être une bonne cible car elle laisse souvent des traces derrière elle (date de commentaire, ou de création d'un post sur un forum ...)

La date de création d'un contenu a aussi l'avantage, ramené à l'échelle d'une page Web, de nous donner une approximation de la date de création effective d'une page, comme étant la plus ancienne (ou première) date d'édition détectée.

Nous voulons maintenant définir une échelle de datation des pages web archivée regroupant l'ensemble des dates qu'il nous sera possible de manipuler.

1. date de téléchargement
2. dernière date de modification
3. première date d'édition

Certain *fragment Web* auront une date d'édition d'autre seront la dernière date de modification ou à la date de téléchargement.

Désagréger pour changer de temporalité

Il n'est pas simple de retrouver une date d'édition dans une page Web vivante ou archivée. Cela a déjà été proposé par plusieurs travaux.

On peut partir sur des indices ou des comparaisons entre version. C'est compliqué oui mais les bénéfices en terme de précision historiques sont impressionnant, afin de l'illustrer nous allons procéder à une expérience dans laquelle nous allons rapidement extraire l'ensemble des dates de création de tous les postes de yabiladi. Tout au long de sa vie la structure du fichier HTML derrière le forum a peut évolué et les class de noeuds sont restée identiques. Nous allons donc faire une extraction spécifique à yabiladi forum et comparer pour chaque page sa première date d'édition vs sa date de download. Nous reprenons donc la répartition proposée au chapitre 4 à laquelle nous ajoutons en bleue la répartition des dates d'éditions.

La réaprtition est plus linéaire et ne relève pas de trous entre 2013 et 2014. Plus intéressant encore, en passant de la temporalité vue depuis le crawler à celle vue depuis le site ou le fragments on peut remonter jusqu'en 2003. Soit une année seulement après la création véritable de yabiladi.com. Un contenu archivé contient plus de mémoire que ce qu'il ne semble offrir de prime abord

Là est tout l'enjeu du chagement d'unité que nous proposons qui est en réalité un changement de temporalité.

De la même manière, dans ses derniers travaux historiographiques (Baschet, 2018), l'historien médiéviste J. Baschet à recourt à W. Benjamin pour réaffirmer la nécessité de rompre avec une vision unilinéaire de l'histoire. Il faut, selon lui, faire éclater la continuité de l'histoire pour en isoler des constellations afin de mieux saisir l'ensemble d'un mouvement historique.

Et il existe d'autres temporalités, comme le présente Husserl tmtc ou les indiens du chiapas. Bref le fragment web c'est un changement d'échelle spatial et temporel. Et voici maintenant le moment de vous le présenter.

5.2 Le fragment Web : définition

A partir de maintenant nous assumons la nécessité de trouver une nouvelle unité d'exploration des archives web baptisé fragment web, s'inscrivant dans la 5ème strate du web et émancé (autant que possible) de tout lien avec le crawler. Cette unité devra autant que possible être relié à une édition ondate pour éviter les crawl legacy et maximiser la présision historique.

Comme la forme de ces fragments sera toujours lié au contexte de l'exploration dans laquelle elle sera utilisée, et comme nous voulons que des sociologues ou des historiens puissent s'en saisir (car un historien demandera toujours à connaître le contexte (cf le papier sur les archives là) la définition suivante sera générique à dessein. Une défini-

tion pratique et son extraction technique sera proposer dans la section suivante et targété pour la question des collectifs migrants etteinds.

Définition

Considérant la page Web comme unité de consultation de base du Web, bâtit sur des modalités d'écriture propre au support numérique et constatant que du point de vue de la perception humaine une page web est le résultat de l'agencement logique de fragments sémantiques distincts, alors :

le fragment est un sous ensemble cohérent ...

5.3 Scraping et méthodologie d'extraction

Extraire de l'information issue d'une page Web

Là on parle de scraping et on fait une revue de l'état de l'art et l'on parle de readability ...

Implémentation technique

Là on parle de rivelaine et de la fonction distance ...

Exemples et discussions

Là on parle de l'automatique vs le fait à la main avec le truc firefox

5.4 Penser une exploration désagrégée

Atténuer les "crawl blindness"

Cohérence relative entre archives

Dédupliquer les corpus

5.5 Intégration à un moteur d'exploration

D'un schéma à un autre

Retour à la détection d'événements

S'éloigner des moteurs d'exploration

Chapitre 6

| Explorations de Collectifs Migrants Éteints

Où l'on parle d'exploration de blogs, de forum et de moments

6.1 À la recherche de l'étonnement : l'analyse exploratoire de données

De Tuckey à Fry

Où l'on explique l'EDA de où ça vient

Abduction, déduction, induction

Où l'on introduit la philosophie générale de l'EDA et on peut faire un lien avec Ginsburg

Méthodologie technique d'exploration

Où l'on explique comment techniquement nous allons procéder en suivant plutôt Fry

6.2 Les traces d'une mutation numérique

D'une communauté vibrante de blogs ...

Là on raconte l'état des blogs en 2008

... à un collectif éteint

Là on raconte l'état des blogs en 2018

Définir l'espace d'exploration

Là on explique la forme des fragments que l'on va chercher à retrouver

Migration d'un territoire Web à un autre

Là comprend que les blogs se sont déplacé vers Fb et Twitter

Conserver son identité numérique

Là on parle de la communauté des blogs

Le Printemps Arabe vu comme un moment-clé

Là on introduit le Printemps arabe marocain

6.3 Un soulèvement en ligne éphémère

Yabiladi.com : porte d'entrée sur la diaspora

Là on explique ce qu'est Yabiladi

La manifestation du 20 Février 2011

Là on rappelle ce qu'est cet événement

Définir l'espace d'exploration

Là on explique la forme des fragments que l'on va chercher à étudier

Voir un site évoluer

Là on explique comment on va visualiser ces fragments

Agréger les contributeurs

Là on s'intéresse au graph des contributeurs

De l'embrasement à l'évasion

Là on regarde les clusters de Threads

6.4 Les Moments Pivot du Web

Les limites de l'archivage du Web

Les archives ne capturent pas le Web comme un environnement

Les moments pivots du Web

Un moment pivot c'est quoi ? Les geste et compagnie ainsi que la micro-histoire

Temporalités d'analyse

Là on se dit que l'exploration désagrégée c'est quand meme pas mal et que l'on peut étudier les archives autour de moments singuliers

Repenser nos archives vis à vis des moments pivots

Là on commence à parler de la suite, du web que l'on souhaite, de la neutralité et des défis à venir de l'archivage

Chapitre 7

| Au Delà Des Archives Web

7.1 Remettre l'humain au cœur des archives

7.2 Fouiller les archives du Web profond

7.3 Les traces nativement numérique

7.4 Vers une sociologie numérique des migrations

Ressources

8.1 References

References are placed alongside their citations as sidenotes, as well. This can be accomplished using the normal `\cite` command.¹

The complete list of references may also be printed automatically by using the `\bibliography` command. (See the end of this document for an example.) If you do not want to print a bibliography at the end of your document, use the `\nobibliography` command in its place.

To enter multiple citations at one location,² you can provide a list of keys separated by commas and the same optional vertical offset argument: `\cite{Tufte2006,Tufte1990}`.

```
\cite[<offset>]{bibkey1,bibkey2,...}
```

¹ The first paragraph of this document includes a citation.

² ; and

8.2 Figures and Tables

Images and graphics play an integral role in Tufte's work. In addition to the standard `figure` and `tabular` environments, this style provides special figure and table environments for full-width floats.

Full page-width figures and tables may be placed in `figure*` or `table*` environments. To place figures or tables in the margin, use the `marginfigure` or `marginfigure` environments as follows (see figure 8.1):

```
\begin{marginfigure}
\includegraphics{helix}
\caption{This is a margin figure.}
\label{fig:marginfig}
\end{marginfigure}
```

The `marginfigure` and `marginfigure` environments accept an optional parameter `<offset>` that adjusts the vertical position of the figure or table. See the “??” section above for examples. The specifications are:




Figure 8.1: This is a margin figure. The helix is defined by $x = \cos(2\pi z)$, $y = \sin(2\pi z)$, and $z = [0, 2.7]$. The figure was drawn using Asymptote (<http://asymptote.sf.net/>).

```

\begin{marginfigure}[<offset>]
...
\end{marginfigure}

\begin{margintable}[<offset>]
...
\end{margintable}

```

Figure 8.2 is an example of the `figure*` environment and figure 8.3 is an example of the normal `figure` environment.





Figure 8.2: This graph shows $y = \sin x$ from about $x = [-10, 10]$. Notice that this figure takes up the full page width.

Figure 8.3: Hilbert curves of various degrees n . Notice that this figure only takes up the main textblock width.



Chapitre 9

| Conclusion

| Bibliographie

- Baschet, J. (2018). *Défaire la tyrannie du présent: Temporalités émergentes et futurs inédits*. L'horizon des possibles. Editions La Découverte.
- Borges, J. (1974). *Fictions*. Collection Folio. Editions Gallimard.
- Brügger, N. (2002). Does the materiality of the Internet matter. *The Internet and society*, pages 13–22.
- Brügger, N. (2009). Website history and the website as an object of study. *New Media & Society*, 11(1-2):115–132.
- Derrida, J. (1995). Mal d'archive. *Paris, Galilee*, page 371.
- Foot, K. and Schneider, S. M. (2006). *Web campaigning (acting with technology)*. The MIT Press.
- Ketelaar, E. (2006). (Dé) Construire l'archive. *Matériaux pour l'histoire de notre temps*, (2):65–70.