

Quentin Lobbé

# **Archives et Fragments Web**

Désagréger les archives Web pour mener une exploration temporelle de traces numériques des migrations

Université Paris-Saclay, École doctorale des sciences et technologies de l'information et de la communication.  
Thèse pour l'obtention du doctorat de Télécom ParisTech et de l'Université Paris-Saclay.



Thèse présentée par **Quentin Lobbé**

LTCI, Télécom ParisTech, Université Paris Saclay & Inria. Paris, France.

quentin.lobbe@telecom-paristech.fr

Sous la direction de :

**Pierre Senellart**, professeur à l'École Normale Supérieure

**Dana Diminescu**, professeure à Télécom ParisTech

Soutenue publiquement à Paris le 9 novembre 2018, devant un jury composé de :

**Bruno Bachimont** (Rapporteur), enseignant-chercheur à l'Université Technologique de Compiègne

**Marc Spaniol** (Rapporteur), professeur à l'Université de Caen Basse-Normandie

**Anat Ben-David**, professeure à l'Open University of Israel

**Dominique Cardon**, professeur associé à Sciences Po Paris

**Bruno Defude**, directeur adjoint de la recherche et des formations doctorales à Télécom SudParis

*last modified June 2018*

Il me demanda de chercher la première page.

Je posais ma main gauche sur la couverture et ouvris le volume de mon pouce serré contre l'index. Je m'efforçais en vain : il restait toujours des feuilles entre la couverture et mon pouce. Elles semblaient sourdre du livre.

- Maintenant cherchez la dernière.

Mes tentatives échouèrent de même; à peine pus-je balbutier d'une voix qui n'était plus ma voix :

- Cela n'est pas possible.

Toujours à voix basse le vendeur me dit :

- Cela n'est pas possible et pourtant cela *est*. Le nombre de pages de ce livre est exactement infini. Aucune n'est la première, aucune n'est la dernière.

*Jorge Luis Borges - Le livre de sable*

## | Remerciements

Ici je remercie plein de gens  
Beaucoup de gens  
Mais vraiment



# | Table des matières

Chapitre 1	Introduction	13
1.1	<i>Introduction générale</i>	13
1.2	<i>Mise en garde</i>	13
Chapitre 2	Du Web aux Représentations en Ligne des Diasporas	15
2.1	<i>Retour aux origines du Web</i>	15
2.2	<i>Le migrant connecté</i>	15
2.3	<i>Le Web, espace de communication et d'organisation</i>	15
2.4	<i>L'Atlas e-Diasporas</i>	16
Chapitre 3	Archiver le Web	17
3.1	<i>Vingt ans d'archivage du Web</i>	17
3.2	<i>Sélectionner, collecter et explorer des corpus</i>	26
3.3	<i>Les archives Web de l'Atlas e-Diasporas</i>	39
Chapitre 4	Traces Discrétisées et Temporalité Figée	41
4.1	<i>Détruire pour mieux archiver</i>	41
4.2	<i>Un temps sans extension</i>	41
4.3	<i>Construire un moteur d'exploration d'archive</i>	43
4.4	<i>Les archives sont des traces indirectes du Web</i>	44
Chapitre 5	Fragmenter les Archives Web	45
5.1	<i>Vers une nouvelle unité d'exploration</i>	46
5.2	<i>Le fragment Web : définition</i>	53

	5.3	<i>Scraping et méthodologie d'extraction</i>	
	5.4	<i>Penser une exploration désagrégée</i>	54
	5.5	<i>Intégration à un moteur d'exploration</i>	54
Chapitre 6		Explorations de Collectifs Migrants Éteints	55
	6.1	<i>À la recherche de l'étonnement : l'analyse exploratoire de données</i>	55
	6.2	<i>Les traces d'une mutation numérique</i>	55
	6.3	<i>Un soulèvement en ligne éphémère</i>	56
	6.4	<i>Les Moments Pivot du Web</i>	57
Chapitre 7		Au Delà Des Archives Web	59
	7.1	<i>Remettre l'humain au cœur des archives</i>	59
	7.2	<i>Fouiller les archives du Web profond</i>	59
	7.3	<i>Les traces nativement numérique</i>	59
	7.4	<i>Vers une sociologie numérique des migrations</i>	59
Chapitre 8		Ressources	61
	8.1	<i>References</i>	61
	8.2	<i>Figures and Tables</i>	61
Chapitre 9		Conclusion	63
Chapitre		Bibliographie	65



## | List of Figures

3.1	Évolution cumulée du nombre d'initiatives d'archivage du Web par année de création (source de données (Gomes et al., 2011) et Wikipédia <a href="https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives">https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives</a> )	21
3.2	Carte des initiatives d'archivage du Web par pays et années de création (source de données (Gomes et al., 2011) et Wikipédia <a href="https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives">https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives</a> )	22
3.3	Demande d'accréditation pour accéder aux zones de consultations des archives Web à la BNF (site François Mitterand)	25
3.4	Localisation (en bleu) des postes de consultation des archives Web à la BNF (Rez-de-Jardin, site François Mitterand)	26
3.5	La double cardinalité d'une ressource Web, d'après (Masanès, 2006)	28
3.6	Graphe dont les nœuds sont labellisés par degré. En théorie des graphes, le degré $deg(v)$ d'un nœud $v$ correspond au nombre de liens incidents (entrant ou sortant) à ce nœud.	29
3.7	Archivage du Web vivant page après page, de $p_1$ à $p_3$	31
3.8	Différentes stratégies adoptées par un crawler $c$ pour collecter les pages $\{p_1, \dots, p_n\}$ d'un même site	33
3.9	Graphe dont les nœuds sont labellisés par degré entrant. En théorie des graphes, le degré $deg^-(v)$ d'un nœud $v$ correspond au nombre de liens incidents entrant à ce nœud.	33
3.10	Fonctionnement général du système de collecte de l'INA	34
3.11	Différences entre les formats WARC (a) et DAFF (b)	36
4.1	"Boulevard du Temple", Louis Daguerre, 1838	42
4.2	Warc vs Daff	42
5.1	Extraits de " <i>Je Vous Salue, Sarajevo</i> ", J.L. Godard (1993) à partir d'une photographie de R. Haviv (1992)	47
5.2	Les 5 strates analytiques du Web, d'après (Brügger, 2009)	49
5.3	Répartition des archives de <i>yabiladi.com</i> dans la WayBack Machine ( <a href="https://web.archive.org/web/*/www.yabiladi.com">https://web.archive.org/web/*/www.yabiladi.com</a> )	50
5.4	Date de création (rouge) d'un post de forum sur <i>yabiladi.com</i>	50
5.5	Dimensions d'exploration des archives Web (ajout de l'acteur)	52

- 8.1 This is a margin figure. The helix is defined by  $x = \cos(2\pi z)$ ,  $y = \sin(2\pi z)$ , and  $z = [0, 2.7]$ . The figure was drawn using Asymptote (<http://asymptote.sf.net/>). 61
- 8.2 This graph shows  $y = \sin x$  from about  $x = [-10, 10]$ . *Notice that this figure takes up the full page width.* 62
- 8.3 Hilbert curves of various degrees  $n$ . 62

## | List of Tables

3.1	Ensemble des champs disponibles dans les fichiers de méta données et de données DAFF	37
4.1	Échelle de datation d'une page Web archivée	41
5.1	Échelle (actualisée) de datation d'une page Web archivée	51



## Chapitre 1

# | Introduction

### 1.1 Introduction générale

Ici l'intro de la thèse.

### 1.2 Mise en garde

*Penser le passé depuis le présent*

Ici on fait un rapide détour par l'historiographie et les difficultés à parler du passé depuis le présent.

*Conservation différentielle et nature des archives Web*

Ici on parle de la raréfaction de la matière Web à mesure que l'on remonte le temps et également à mesure que le web fournit du contenu.



# | Du Web aux Représentations en Ligne des Diasporas

## 2.1 Retour aux origines du Web

## 2.2 Le migrant connecté

## 2.3 Le Web, espace de communication et d'organisation

The Web is the main publishing application of the Internet. As such, it consists mainly of the combination of three standards, the URI (Berners-Lee 1994) defining a naming space for object on the Internet, 6 HTTP (Fielding et al. 1999) defining a client-server interaction protocol using hyperlinks at its core, and HTML (Berners-Lee and Connolly 1995) an SGML DTD that defines the layout rendering of pages in browsers. The implementation of these three standards enables any computer connected to the Internet to become a publishing system.

But the fact that it is actionable on the Web changes the way references are used by fragmenting content to smaller addressable pieces and overall favoring transversal navigation and access to content which in return, deeply changes the nature of writing as well as reading (Aarseth 1997; Landow 1997; Bolter 2001).

Géopolitique de l'hypertexte

Le web est un digital cultural artifact (Lyman and Kahle 1998)

the Web does, to a large extent, re-use previous forms of publishing 12 (Crowston and Williams 1997; Eriksen and Ihlström 2000; Shepherd and Polanyi 2000), it also invents new ones.

This characterization of the Web as a distributed hypermedia openly and permanently authored at a global scale entails that Web archiving can only achieve preservation of limited aspects of a larger and living cultural artifact.

the interconnectedness of content is a major quality of the Web that raises issues when it comes to archiving.

## 2.4 L'Atlas e-Diasporas



## | Archiver le Web

Face à la disparition totale ou partielle des sites Web recensés par l’atlas e-Diasporas (Chapitre 2), il a été décidé de lancer une campagne d’archivage afin de préserver cet héritage numérique et d’anticiper, par là même, la tenue de futures recherches. Sans cette initiative, mes travaux de thèse n’auraient pas pu exploiter et questionner les traces d’un Web aujourd’hui passé.

De part la nature même du médium, le Web demande de penser et de mettre en place un archivage particulier, basé sur des techniques de collectage dédiées. Dans ce chapitre, nous évoquerons la genèse de l’archivage du Web qui, au tournant des années 2000, a connu un essor mondial, mobilisant nombre d’acteurs et d’institutions. Nous introduirons ensuite, d’un point de vue technique, les principales méthodes de sélection, collecte et stockage des corpus à archiver. Nous présenterons enfin les contours des archives e-Diasporas à proprement parler. Ses particularités et ses caractéristiques. Sa durée et son étendue.

Bien que cette thèse se concentre sur l’exploration d’archives Web déjà existantes, il nous semble important d’évoquer la façon dont ces dernières sont constituées en amont afin de mieux saisir les biais analytiques (Chapitre 4) qui motiveront la présentation de notre principale contribution (Chapitre 5). Ce faisant, les éléments que nous nous apprêtons à présenter s’appuieront principalement sur l’ouvrage de J. Masanes : *"Web Archiving"* (Masanes, 2006) qui reste encore aujourd’hui une référence.

### 3.1 Vingt ans d’archivage du Web

En Octobre 2016, se tenait à la Bibliothèque Nationale de France (BNF) une grande conférence anniversaire réunissant, pour les 20 ans de l’archivage du Web<sup>1</sup>, les acteurs français de la pratique. Alors qu’était évoqués les conditions du partage du dépôt légal du Web national entre la BNF et l’INA, il a été rappelé qu’à l’origine chacune des

<sup>1</sup> [http://www.bnf.fr/fr/professionnels/anx-journees-pro-2016/a.jp\\_161122\\_23\\_archivage\\_web.html](http://www.bnf.fr/fr/professionnels/anx-journees-pro-2016/a.jp_161122_23_archivage_web.html)

<sup>2</sup> [http://multimedia.bnf.fr/video/prof/161123\\_10\\_dl\\_web.mp4](http://multimedia.bnf.fr/video/prof/161123_10_dl_web.mp4)

deux institutions souhaitait se voir attribuer la pleine gestion de ce dépôt. L'INA mettait en avant ses compétences techniques acquises en archivant les flux audiovisuels nouvellement introduits dans le paysage culturel. La BNF, pour sa part, s'appuyait sur son expérience pluricentenaire de préservation du patrimoine<sup>2</sup>.

Cette querelle initiale et son dénouement (la cotutelle du dépôt légal) sont à l'image de l'histoire même de l'archivage du Web: la conjugaison d'une tradition longue de sauvegarde des savoirs et d'un ensemble de techniques de collecte nouvellement pensées pour cet objet complexe qu'est le Web, le tout porté par une poignée de pionniers.

### *Préserver la mémoire collective*

L'archivage du Web s'inscrit dans la tradition longue des techniques d'élaboration et de conservation de la mémoire collective. Tradition qui remonte aux origines même de l'humanité où technique et mémoire se trouvaient étroitement liées.

A. Leroi-Gourhan fait émerger, de l'étude de séries d'objets (silex taillés, percuteurs, harpons, etc) et de figures préhistoriques (gravures et peintures des grottes ornées), une ligne de rencontre entre technique et mémoire (Leroi-Gourhan, 1964). Le préhistorien décrit la technique comme un système évolutif, soumis aux lois générales de la technologie et apparaissant comme transversal à des cultures parfois diverses et éloignées<sup>3</sup>. La technique est chargée, en elle-même, de l'histoire passée des continuités, ruptures et transformations technologiques dont elle est l'aboutissement à un instant t.

Avec Leroi-Gourhan, la technique devient mémoire. Elle peut en être chargée et/ou être conçue à dessein de la conserver. Involontairement, le silex taillé porte en lui la trace de l'homme qui l'a élaboré. Lorsque le tailleur finit par mourir, son geste continue à s'extérioriser à travers l'outil qui demeure. Précieux indice pour celui qui vient à sa suite ou pour l'archéologue qui, des millénaires après, saura grâce à cet objet assembler les traces fragmentées d'une pratique passée. Mais l'homme aurait aussi très bien pu choisir, en conscience, d'inscrire son expérience individuelle sur des supports de mémoire dédiés. L'écriture est ainsi l'une des premières techniques de la mémoire, utilisée par l'humanité depuis le néolithique. L'écriture est en cela une *mnémotechnologie* (Stiegler, 1998).

Poursuivant son évolution, l'humanité développe plus avant les techniques de transmission des savoirs pour sélectionner et agréger ses expériences individuelles en une mémoire collective. Des espaces et des structures voient le jour, appuyés par divers pouvoirs politiques ou religieux, avec le double objectif de préserver et d'administrer l'héritage collectif. J. Derrida décrit ainsi le geste d'archiver comme un "*geste de*

<sup>3</sup> Leroi-Gourhan associe les formes animales des grottes ornées à des signes, réalisant des couplages basés sur l'observation (comptages et statistiques) de dizaines de cavités. Il cherche à établir une échelle évolutive des styles pariétaux, transversale aux premiers âges de l'Europe de l'Ouest (Leroi-Gourhan, 1984)

*pouvoir*" (Derrida, 2014). Choisir ce que l'on garde ou non dans les archives ne peut être que le fruit d'une hégémonie, d'une hiérarchie et "*d'un certain nombre d'opérations de pouvoir*" rendues légitimes par une institution. L'État est ainsi caractérisé par *sa capacité d'accumuler, contrôler et exploiter la mémoire collective* (Stiegler, 1991), capacité dont on retrouve divers incarnations au cours de l'histoire :

- Au IV<sup>e</sup> millénaire av. J.C, les tablettes d'argiles étaient accumulées par les mésopotamiens pour constituer les premières bibliothèques
- Entre 535 et 555, Cassiodore pense le Monastère de Vivarium comme un lieu de transmission où, pour la première fois, seraient associés culture savante et christianisme
- François I<sup>er</sup> crée le dépôt légal<sup>4</sup> en France, par l'ordonnance royale du 28 décembre 1537, à des fins de préservation culturelle mais également de contrôle politique

Les siècles passent et les archives s'adaptent à la transformation des supports de mémoire et à l'émergence de formes nouvelles d'enregistrement. Avec l'arrivée des technologies analogiques<sup>5</sup>, il faut désormais capter et archiver des flux d'images et de sons, ce qui conduira en France à la création de l'Institut National de l'Audiovisuel (INA) en 1974. L'apparition du numérique<sup>6</sup> marque la dernière étape de ce cheminement en ouvrant la voie à un renouvellement des formes de lecture et d'étude des archives. L'accès à distance de documents numérisés facilite leur consultation, mais il devient également possible de les qualifier, de les annoter ou de les mettre en relation, et ce, de manière large voire exhaustive (Borgman, 2000) :

- En 1971, le projet Gutenberg commence à collecter des copies numériques (recopiées et tapées *à la main*) d'ouvrages du domaine public
- Le Thesaurus Linguae Graecae cherche, depuis 1972, à numériser la plupart des textes littéraires rédigés en grecs anciens et toujours subsistants

Mais si le numérique permet aujourd'hui de revisiter des ressources anciennement archivées, il est aussi créateur d'objets nativement numériques tout autant porteurs d'un héritage à préserver. Le web en est la parfaite illustration.

### *Un héritage numérique*

L'archivage du Web débute à la fin des années 90, et plus précisément en 1996 lorsque se développent les premières initiatives de préservation du Web, soit 4 années à peine après la publication de la première

<sup>4</sup> "*Nous avons délibéré de faire retirer, mettre et assembler en notre librairie toutes les livres dignes d'être vues qui ont été ou qui seront faites, compilées, amplifiées, corrigées et amendées de notre temps*", extrait de l'ordonnance royale (Dougnaç and Guilbaud, 1960)

<sup>5</sup> Cinématographie, photographie, radiodiffusion, etc

<sup>6</sup> Bases de données, logiciels, interfaces, etc

<sup>7</sup> <http://pandora.nla.gov.au/>

<sup>8</sup> <https://web.archive.org/web/20040206225053/https://www.kb.se/kw3>

<sup>9</sup> <https://archive.org/>

<sup>10</sup> Nordic Web Archive

page sur la toile (Section 2.1). La National Library of Australia est ainsi à l'initiative du projet Pandora<sup>7</sup> qui vise à archiver les publications en ligne australiennes sur la base d'une collecte sélective et continue de sites Web australiens. La Swedish Royal Library, quant à elle, lance le projet Kulturarw<sup>8</sup> qui s'essaye à une collecte "*intégrale*" et espacée dans le temps des sites du Web suédois (Arvidson et al., 2000).

Mais c'est avec la création d'Internet Archive par B. Kahle la même année (Kahle, 1997), que s'écrit véritablement la première page de l'histoire des archives du Web. Ingénieur et activiste, Kahle s'inspire de la Bibliothèque d'Alexandrie pour motiver la création d'une organisation à but non lucratif afin de rendre accessible au plus grand nombre le passé du Web<sup>9</sup>. Utilisant un crawler développé pour le compte de son autre société Alexa Internet, Kahle revendiquait, dans les premières années de la collecte, être capable d'archiver au moins une fois tous les deux mois chacun des sites de l'ensemble du Web (Mohr et al., 2004). La revente d'Alexa au groupe Amazon en 1999 va lui permettre de pérenniser financièrement Internet Archive, qui depuis ce temps n'a eu de cesse d'archiver le Web.

Ces pionniers de l'archivage sont rapidement suivis par la Finlande en 1997, le Danemark en 1998 et d'autres pays nordiques rassemblés autour du projet NWA<sup>10</sup> (Hallgrinsson and Bang, 2003). En 2003, la publication par l'UNESCO de la *Charte sur la conservation du patrimoine numérique* (UNESCO, 2003) marque un nouveau tournant pour l'archivage du Web en reconnaissant la valeur universelle d'une telle démarche et l'urgence face à la disparition potentiel de tout, ou d'une partie, de l'héritage numérique mondial :

*"Le patrimoine numérique mondial risque d'être perdu pour la postérité. Les facteurs qui peuvent contribuer à sa perte sont l'obsolescence rapide du matériel et des logiciels qui servent à le créer, les incertitudes concernant les financements, la responsabilité et les méthodes de la maintenance et de la conservation et l'absence de législation favorable à sa préservation. L'évolution des attitudes n'a pas suivi celle des technologies. L'évolution numérique a été trop rapide et trop coûteuse pour que les pouvoirs publics et les institutions élaborent en temps voulu et en connaissance de cause des stratégies de conservation. La menace qui plane sur le potentiel économique, social, intellectuel et culturel du patrimoine, pierre angulaire de l'avenir, n'a pas été pleinement saisie."*

(Charte sur la conservation du patrimoine numérique, Article 3)

Pour de nombreuses bibliothèques nationales, la charte de l'UNESCO fait l'effet d'un accélérateur (Figure 3.1). Les institutions sont encouragées dès 2003 à archiver leur Web national (Gomes et al., 2011). Mais notons ici que la notion de Web national reste discutable (Abiteboul et al., 2002), il s'agira souvent de crawler le Web en fonction d'une extension de nom de domaine donnée (.fr, .jp, .uk, etc), extension qui ne couvre pas exhaustivement l'ensemble des sites associés à un domaine national précis, elle est plutôt à considérer comme une borne

inférieure de celui-ci (Koehler, 1999). Le cas des corpus de l'Atlas e-Diasporas en est un très bon contre-exemple, nombre de sites migrants possédant une extension générique (.com, .net) ou correspondant au pays d'accueil plutôt qu'au pays d'origine (Leclerc, 2012).




Figure 3.1: Évolution cumulée du nombre d'initiatives d'archivage du Web par année de création (source de données (Gomes et al., 2011) et Wikipédia [https://en.wikipedia.org/wiki/List\\_of\\_Web\\_archiving\\_initiatives](https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives))

Ces nouveaux acteurs de l'archivage du Web peuvent être classés suivant la terminologie introduite par J. Masanes (Masanès, 2006), entre initiatives publiques ou privées, poursuivant un but lucratif ou non. L'accès aux corpus archivés peut être entièrement public ou restreint et limité, en ligne ou physique (machine de consultation dans une bibliothèque). Par exemple, Internet Archive est une initiative à but non lucratif, avec un accès public à l'ensemble de ses corpus, en ligne depuis 2001 et physique depuis 2002<sup>11</sup>.

Une autre manière de catégoriser ces initiatives est de regarder la nature des corpus archivés. Nous avons déjà évoqué les corpus territoriaux censés capturer les contours d'un Web national. Cette notion peut être également transposée à plus fine échelle : celle d'une région ou d'une ville (Boudrez and Van den Eynde, 2002). Un corpus d'archive peut être conçu pour cibler une thématique donnée, souvent centrée sur des événements politiques (Voerman et al., 2002; Schneider et al., 2003) : élections, référendums, etc. Certaines initiatives s'affranchissent même de barrières géographiques devenues contraignantes en préservant des sites de domaines nationaux étrangers (Gomes et al., 2009).

Enfin, il est possible de voir les corpus d'archives Web par rap-

<sup>11</sup> La Wayback Machine est officiellement lancée en 2001. Avant cette date les corpus d'Internet Archives n'étaient pas accessibles au public. En 2002, une copie intégrale des archives est consultable à la Bibliotheca Alexandrina, en Égypte

<sup>12</sup> <http://warp.da.ndl.go.jp/search/>

<sup>13</sup> <https://www.bl.uk/collection-guides/uk-web-archive>

<sup>14</sup> [https://fr.wikipedia.org/wiki/Mémoire\\_cache](https://fr.wikipedia.org/wiki/Mémoire_cache)

port à l'utilisation que l'on en fait. Certains sont ouvertement tournés vers la consultation publique (Internet Archives, à nouveau), d'autres sont constitués à des fins universitaires (on pense au corpus japonais WARP<sup>12</sup> de la National Diet Library). La British Library, de son côté, fait de ses archives Web une utilisation détournée, voire cachée, en chargeant la version passée d'une page Web de son site si cette dernière n'est momentanément ou définitivement plus accessible à un visiteur<sup>13</sup>. L'un des plus gros corpus d'archives Web reste en revanche celui détenu par Google qui permet d'accéder depuis le cache<sup>14</sup> de son moteur de recherche à une version précédemment crawlée d'une page. Notons, pour terminer ce tour d'horizon, que même si elles sont nombreuses de part le monde, les initiatives d'archivage du Web sont historiquement et géographiquement le fait d'états occidentaux (Figure 3.2). Les continents sud Américain et Africain (hormis la la Bibliotheca Alexandrina) sont absents de ce paysage, rendant encore plus précieux les corpus transnationaux archivés par l'Internet Archives et l'Atlas e-Diasporas.




Figure 3.2: Carte des initiatives d'archivage du Web par pays et années de création (source de données (Gomes et al., 2011) et Wikipédia [https://en.wikipedia.org/wiki/List\\_of\\_Web\\_archiving\\_initiatives](https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives))

En vingt années d'existence, les archives du Web ont agrégé autour d'elles une communauté de chercheurs et d'ingénieurs participant à sa promotion. L'International Internet Preservation Consortium (IIPC) est fondé en 2003 dans l'idée de proposer des rapports et des suivis

réguliers de l'archivage<sup>15</sup> et des workshops sont organisés (l'IWAW, International Web Archiving Workshops). Mais le fait est de constater que la dynamique visible à la fin des années 2000 est en train de se tasser. En 2017, une seule et unique initiative a vu le jour (en Belgique autour du projet Promise<sup>16</sup>). Les vastes projets de recherche et d'exploitation des archives Web que sont ARCOMEM (Risse et al., 2014), LAWA (Spaniol and Weikum, 2012) et LIWA (Denev et al., 2009) n'ont pas trouvé de successeurs et, en 2018, l'Internet Memory Foundation a annoncé stopper ses activités d'archivage. Enfin, rappelons que la position centrale d'Internet Archive dans cet écosystème ne la met pas à l'abri d'une possible disparition. En 2016, B. Kahle prévoyait (notamment en réaction à l'élection de D. Trump à la tête des États Unis) de déplacer une nouvelle copie intégrale d'Internet Archive au Canada<sup>17</sup>. Et n'oublions pas que, jusqu'à présent, la survie d'Internet Archive est et reste étroitement liée à son fondateur, la question de sa succession et de la pérennité du corpus après sa mort devra être rapidement abordée.

Mais alors que les institutions semblent s'en détourner, le futur des archives Web viendra peut être de ceux que M. Graham, directeur de la WayBack Machine, nomme les "*rogue archivists*"<sup>18</sup>. S'inscrivant dans les pas d'A. Schwartz<sup>19</sup>, les rogues archivists sont des activistes et libristes militants s'appropriant politiquement la question des archives. Soit qu'ils considèrent le Web et son contenu comme un commun de l'Humanité (Coriat and others, 2015), soit qu'ils voient dans les archives un moyen de faire perdurer la mémoire de minorités opprimées (De Kosnik, 2016). Ils administrent de manière autonome certains des 7000 crawlers qui alimentent quotidiennement Internet Archive. Encore mineure, au regard des volumes globaux d'archives Web, il est néanmoins possible de déceler la trace de leurs contributions dans les travaux d'A. Ben David (Ben-David and Amram, 2018) qui révèle que les archives du Web Nord Coréen (présentes dans le corpus d'Internet Archive) n'ont pas été collectées par des crawlers institutionnels mais par des crawlers indépendants, non assujettis à la géopolitique des proxys.

### *Le cas des archives Françaises*

En France, l'archivage du Web est l'aboutissement singulier de dix années d'expérimentations techniques et de construction d'un cadre législatif inédit. Aujourd'hui, deux institutions se partagent le périmètre du dépôt légal du Web : la Bibliothèque Nationale de France (BNF) et l'Institut National de l'Audiovisuel (INA).

Crée par François 1er, le *dépôt légal* est l'obligation pour tout éditeur (imprimeur, producteur, importateur, etc) de déposer chaque docu-

<sup>15</sup> [http://internetmemory.org/images/uploads/Web\\_Archiving\\_Survey.pdf](http://internetmemory.org/images/uploads/Web_Archiving_Survey.pdf)

<sup>16</sup> <https://promise.hypotheses.org/>

<sup>17</sup> <http://blog.archive.org/2016/11/29/help-us-keep-the-archive-free-accessible-and-private/>

<sup>18</sup> [https://youtu.be/33\\_fnPwaEM0](https://youtu.be/33_fnPwaEM0)

<sup>19</sup> En 2011, Schwartz hacke la base de données de l'éditeur JSTOR afin de "*libérer*" plusieurs millions d'articles scientifiques payants, dont une part importante appartenait au domaine public (voir *The Internet Own Boy* réalisé par B. Knappenberger en 2014 <https://archive.org/details/TheInternetsOwnBoyEsp>). Schwartz est à l'origine de contributions considérables, à la fois sur des aspects techniques du Web (développeur du format de flux RSS), mais également sur la question plus politique de l'accès universel aux connaissances.

ment dont il a la charge (en France) à la BNF ou auprès de l'organisme le plus adapté à la nature particulière de ce document. Tout ce qui se publie et s'édite en France est donc directement collecté par la BNF. L'INA, quant à elle, administre les archives radio et télé. Elle fut initialement créée pour en faire une exploitation commerciale et destinée aux professionnels de l'audiovisuel. L'État français est l'un des premiers états au monde à avoir posé la question des conditions de la mémoire culturelle et patrimoniale du Web. Le Web devait rentrer dans le périmètre du dépôt légal et c'est ainsi que furent posées les bases d'un futur *dépôt légal du Web*.

Les tractations commencent officiellement en 2001. En s'appuyant sur la directive européenne 2001/29/EC<sup>20</sup>, dite *Information Society Directive*, l'Assemblée Nationale ouvre au débat la discussion du *Projet de loi sur la société de l'information*<sup>21</sup>. Cette loi vise à adapter le droit français aux NTIC en matière de libertés de communication, de commerce en ligne, mais également de droit d'auteur. De ces débats découle, en 2006, l'adoption de la loi DADVSI<sup>22</sup> relative *au droit d'auteur et aux droits voisins dans la société de l'information* qui définit le cadre légale des archives Web à venir :

*"Les logiciels et les bases de données sont soumis à l'obligation de dépôt légal dès lors qu'ils sont mis à disposition d'un public par la diffusion d'un support matériel, quelle que soit la nature de ce support. Sont également soumis au dépôt légal les signes, signaux, écrits, images, sons ou messages de toute nature faisant l'objet d'une communication au public par voie électronique."* (Loi DADVSI, Article 21)

La BNF et l'INA souhaitant toutes deux se voir confier le plein contrôle du dépôt légal de Web par l'État, les équipes de J. Masanès (BNF) et de T. Drugeon (INA) se lancent l'une comme l'autre dans la course à l'archivage dès tournant des années 2000, c'est à dire bien en amont de tout arbitrage politique. Comme nous le verrons dans la section suivante (Section 3.2), la masse de travail à mettre en place pour débiter une collecte est considérable, l'histoire de l'archive du Web en France est donc tout autant l'aboutissement d'une volonté politique que le fruit d'années de recherches et développements. D'un point de vue purement technique, les deux institutions suivent des directions divergentes : la BNF et J. Masanès s'associent à la définition du format d'archivage WARC, l'INA et T. Drugeon créent le format DAFF et développent un crawler indépendant<sup>23</sup>. L'INA lance sa collecte de sites Web de manière expérimentale en 2009 alors que l'État s'oriente vers un partage du dépôt légal : une solution à deux têtes. Le cadre de cette partition est défini par le décret du 19 Décembre 2011<sup>24</sup> qui établit que :

– La BNF archivera l'ensemble du domaine national français et d'outre-

<sup>20</sup> [https://en.wikipedia.org/wiki/Copyright\\_Directive](https://en.wikipedia.org/wiki/Copyright_Directive)

<sup>21</sup> <http://www.assemblee-nationale.fr/11/projets/pl3143.asp>

<sup>22</sup> <https://www.legifrance.gouv.fr/affichTexte.do?cidTexte=JORFTEXT000000266350>

<sup>23</sup> Nous discuterons dans la section 3.2 des aspects techniques des divers formats d'archivage

<sup>24</sup> <https://www.legifrance.gouv.fr/affichTexte.do?cidTexte=JORFTEXT000025002022&categorieLien=id>



mer au moins une fois par an. Par là, sont identifiés tous les sites Web en .fr ainsi qu'une liste blanche de sites en .com, .org, .net, etc *"édités par des personnes physiques ou morales domiciliées en France"*.

- L'INA archivera un sous ensemble thématique du Web français centré sur les sites dit *médias* (sites des services des médias audiovisuels, Web TV et Web radios, programmes radio et télé, professionnel de l'audiovisuel, etc). La fréquence de collecte sera variable et adaptée à la nature même des mises à jour de ces sites (chaque jour, semaine, mois, etc)

Si le périmètre de la collecte de la BNF reste classique au regard de ses consœurs mondiales, le corpus archivé par l'INA, lui, est tout à fait singulier. La collecte se concentre sur un jeu de 14.000 sites Web médias (sélectionnés manuellement). Seulement 30% d'entre eux ont une extension .fr contre 50% en .com (Drugeon, 2005). L'INA intègre à son corpus des sources vidéos (de youtube et dailymotion dès 2010), des flux RSS, des Tweets (depuis 2014), etc. Les deux institutions offrent également la possibilité à des chercheurs de constituer des corpus tiers et portés sur une thématique précise : l'ANR Web90 est montée en partenariat avec la BNF<sup>25</sup> autour des premières années du Web français (Schafer and Thierry, 2016), l'INA réalise une collecte dédiée aux attentats de Paris fin 2015<sup>26</sup>. L'INA est enfin la seule des deux institutions à avoir encore aujourd'hui une équipe technique dédiée à la recherche et à l'exploitation de ses archives Web.

Les corpus de la BNF et de l'INA se veulent donc complémentaires. Ils appartiennent à la catégorie des initiatives publiques mais n'offrant qu'un accès physique aux contenus archivés : il n'y a pas de portail en ligne de consultation des archives. Le chercheur doit se déplacer dans l'un des 31 centres locaux de l'INA ou, s'il est à Paris, il reste possible d'accéder aux deux corpus depuis la BNF.

\*\*\*

Je reprend ici, le *je* pour parler d'une expérience personnelle. Courant 2017, je me suis rendu à la BNF (site François Mitterrand) afin d'y consulter les archives de l'INA et de la BNF et tester les modalités d'accès aux corpus. Ce récit ne vaut pas généralité, mais doit être pris comme un témoignage d'une exploration d'une heure trente dans la bibliothèque avant de trouver les archives. Je pensais tout d'abord (en me fiant aux indications du site Web) qu'il était possible de consulter les archives depuis le réseaux Wifi du lieu. Après divers échecs, les bibliothécaires m'ont progressivement fait passer d'interlocuteur en interlocuteur jusqu'à finalement me faire accéder (moyennant une demande d'accréditation, Figure 3.3) à l'une des salles du Rez-de-Jardin de la BNF (Figure 3.4). Là les archives de l'INA ne sont consultables

<sup>25</sup> <https://web90.hypotheses.org/>

<sup>26</sup> <https://asap.hypotheses.org/173#more-173>



Figure 3.3: Demande d'accréditation pour accéder aux zones de consultations des archives Web à la BNF (site François Mitterrand)




Figure 3.4: Localisation (en bleu) des postes de consultation des archives Web à la BNF (Rez-de-Jardin, site François Mitterrand)

que depuis une poignée de postes labellisés *Inathèque*. Les archives de la BNF, elles, sont accessibles depuis l'ensemble des machines de la zone. Une fois connecté, un moteur de recherche classique nous permet de faire des recherches par URL (pour la BNF) et plein texte (pour l'INA), il n'est en revanche pas possible de sauvegarder ses recherches ou de les exporter d'une quelconque manière. Je me suis donc servi de mon téléphone pour photographier les pages Web qui m'intéressaient. Je ne cherche pas ici à pointer du doigt ou accuser. Au contraire j'ai été étonnamment surpris de voir que la consultation des archives Web à Paris relève d'une véritable expédition et je remercie les bibliothécaires d'avoir finalement su me guider. Mais s'il ne faut pas faire grief de leur méconnaissance, force est de constater que nous ne devons pas être très nombreux à consulter les archives Web là bas et que celles ci ne sont pas particulièrement mise en avant après du public et du personnel.

\*\*\*

Les conditions d'accès restreintes aux corpus de l'INA et de la BNF ne jouent pas en la faveur d'une démocratisation de leur exploitation. Auprès du grand public d'une part, mais également vis à vis de potentiels chercheurs voulant questionner les archives. S'il reste tout à fait possible de venir étudier une liste prédéfinie d'URL et de sites (en lecture seule), les modalités d'accès n'encouragent pas à l'exploration des corpus ni à la possibilité de mener des recherches larges et/ou automatisées (il n'y a pas d'API par exemple).

### 3.2 Sélectionner, collecter et explorer des corpus

Archiver le Web a rapidement été considéré comme une nécessité. Mais l'enthousiasme des premières années a soulevé nombre d'oppositions (Masanès, 2006) : 1) la qualité des documents publiés sur le Web ne serait pas suffisante pour justifier leur sauvegarde, 2) le Web n'a pas besoin d'être collecté puisque par construction il se préserve lui même, 3) archiver le Web est une opération trop compliquée à mettre en place.

La première remarque, qui témoigne du conservatisme des éditeurs face à l'arrivée de contenus amateurs, issus du Web et publiés hors de leurs monopoles, s'est atténuée avec le temps et surtout, rappelons le, grâce à l'impacte de la charte de l'UNESCO (UNESCO, 2003). La seconde objection, ne résiste pas non plus à la réalité du Web. Le Web est un milieu volatile qui, dans une certaine mesure, peut effectivement être considéré comme *self preserving* mais dont une partie importante du contenu reste éphémère. Enfin, nous présenterons les aspects tech-

niques et méthodologiques déployés pour rendre possible l'archivage du Web et explorer ses versions passées.

### *Un objet éphémère et multiforme*

À l'époque où le Web ne contenait qu'une poignée de pages et de sites, la question de son auto-préservation<sup>27</sup> fut posée. Le Web s'archivait-il déjà de lui-même ?

Lorsqu'un nouveau contenu est publié, il est possible de reléguer en bas de page les éléments plus anciens, à la manière d'une pile. Les *content management system* (CMS<sup>28</sup>), apparus avec l'essor des blogs, avaient ainsi pour vocation de stabiliser ce processus de création et suppression de contenus en ligne, en reléguant les publications passées dans une section d'*archives* dédiée. Rien n'empêche également un site Web d'être copié dans son intégralité puis redéployé sur de nouveaux serveurs pour le préserver. Le numérique facilite et rend possible la reproduction à l'infini de ses objets. Ainsi, une page Web aurait théoriquement pu ne jamais disparaître de la toile. Mais il fut montré, dès le début des années 2000, que malgré ces possibilités, le Web restait un milieu hautement instable. La disparition de contenu est un phénomène inhérent au Web.

La durée de vie d'un site Web, peut être calculée par rapport à la mesure de sa *half life*, soit la durée qu'il faut pour que la moitié de son contenu (ici ramené au nombre de pages<sup>29</sup>) disparaisse du Web (Koehler and others, 2004). Dès 1999, la *half life* moyenne d'un site Web est ramenée à 50 jours (Cho and Garcia-Molina, 1999), estimation qui doit être relativisée par rapport au contexte de publication du site et à la nature de ses pages (McDonnell et al., 1999; Fetterly et al., 2003). De même, 80% des pages Web collectées entre 2003 et 2004, par les archives du Web japonais ont été effacées en moins d'un an du Web vivant (Toyoda and Kitsuregawa, 2006). Pour préserver le Web il faut donc intervenir et archiver avant qu'une page ne soit détruite. Ainsi, avant toute collecte, l'archiviste doit prendre en compte les changements susceptibles d'intervenir sur une page ciblée, afin de minimiser la perte d'information.

Les changements subis par une page Web au cours de son existence sont multiples (Douglass et al., 1998; Adar et al., 2009), allant de la modification de son contenu jusqu'à une évolution de la structure des liens qui la relie au reste du site. La fréquence de changement d'une page peut être estimée et prédite en s'appuyant sur des versions précédemment archivées (Chawathe and Garcia-Molina, 1997; Khoury et al., 2007). Il est possible d'affiner l'estimation de cette fréquence en catégorisant les changements par types (structurels, sémantiques ou cosmétiques) (Yadav et al., 2007). Plutôt que de considérer chaque

<sup>27</sup> traduit ici de l'anglais "*self preserving*" (Spinellis, 2003)

<sup>28</sup> Wordpress, Drupal, Joomla!, etc


<sup>29</sup> La *half life* peut être appliquée à d'autres objets numériques comme des bases de données ou des documents scannés. Cette mesure est elle-même dérivée des techniques de datation des atomes.

page indépendamment les unes des autres, les changements peuvent être détectés à l'échelle d'un site ou d'un réseau. On s'appuyera alors sur la présence de liens hypertextes (Liu et al., 2000) ou sur des relations hiérarchiques plus marquées (Lim and Ng, 2001). Dans la suite de ce manuscrit, nous nous limiterons à considérer comme changements les seuls actes de création, de modification ou de suppression d'une partie ou de l'ensemble d'une page Web.

Il faut finalement attendre qu'il soit archivé, pour pouvoir considérer le Web comme un support d'informations *self preserving*. Ce n'est qu'une fois les corpus d'archives rendus accessibles depuis le Web lui-même (Brügger, 2009), que l'on peut considérer qu'il garde en lui la trace (mesurée et mesurable) de ses états passés.

Par ailleurs et à la différence d'autres types de documents à archiver, une page Web possède ce que J. Masanès (Masanès, 2006) nomme une double cardinalité.

Figure 3.5: La double cardinalité d'une ressource Web, d'après (Masanès, 2006)



La cardinalité est le nombre d'instances en circulation d'un artéfact donné : un musée conservera des pièces uniques et originales, une librairie mettra à disposition de ces visiteurs des copies. La cardinalité donne toute sa valeur à un objet archivé et influence les techniques de préservation. Jusqu'à l'invention de l'imprimerie, pour archiver un livre il fallait le copier à la main. L'original était conservé dans un lieu donné et les copies envoyées vers d'autres bibliothèques (Canfora, 1990). L'original se perdant parfois, la copie (rectifiée ou annotée) devenait à défaut œuvre de référence. Mais la notion d'original disparaît avec l'imprimerie. Le livre dans sa forme est stabilisée, les bibliothèques possédant toute la même version d'un ouvrage devenu reproductible à l'identique (Febvre and Martin, 2013). Ainsi Au contraire du livre, sites et pages Web ont la singularité de présenter une double cardinalité :

1. les fichiers sources, hébergés sur un serveur donné

## 2. l'infinité d'accès possibles à cette source

D'une machine à l'autre ou d'un écran à l'autre, une page Web sera toujours vue différemment (Bon, 2014). Soit que la taille de l'écran (ordinateur, smartphone, tablette, etc) aura modifié son aspect, soit que la qualité de la connexion à Internet n'aura pas permis de tout charger, ou encore que l'historique de navigation<sup>30</sup> aura influencé l'affichage de la page à nos yeux. C'est pour cela que J. Masanès propose de parler de *ressource Web* pour nommer tout objet Web susceptible d'être archivé. Une ressource Web est un document unique dont la source peut être identifiée précisément mais interprétée d'une infinité de manière possibles. Depuis son navigateur, derrière son écran. Pour l'archiviste se pose alors la question de quoi archiver ? L'originale ou toutes les interprétations d'une même page ? Arrivé à ce point, archiver le Web revient donc à prendre en compte l'ensemble des états successifs d'une ressource Web afin de ne rien rater. Une fois la fréquence d'archivage décidée, la collecte peut être opérée du point de vue de la source ou du point de vue de l'internaute naviguant derrière son écran. Où l'archiviste choisira-il de se positionner, lui, et ses outils de collecte ?

### Sélection

Toute collecte sur le Web débute par le choix d'un point d'entrée clairement identifié. L'archiviste ne peut se permettre de dériver au hasard du Web pour trouver les sites qui l'intéressent. La **sélection** désigne donc l'ensemble des techniques mises en place pour définir ce ou ces points d'entrée. S'agit-il d'un site Web précis ? D'une liste de pages Web ? D'un masque ou d'un pattern d'URL à satisfaire ? À quelle profondeur débiter l'archivage ? Doit-on commencer par collecter la page principale d'un site, la *front page*, ou un sous ensemble de pages contenant un mot clé donné ?

Le principal critère de sélection définissant le périmètre d'un corpus à archiver reste l'extension d'URL. Les .fr, .uk et autres .ma définissent le cadre grossier d'un domaine national sur le Web (Section 3.1). La sélection s'opère alors en validant un masque d'URL ou une heuristique prédéfinie<sup>31</sup>. Il est également possible de dessiner les contours d'une archive en partant d'une liste initiale de sites Web, appelés sites sources et liés à une thématique précise. Il faut pour cela faire appelle, en amont de toute collecte, à des experts (sociologues, historiens, etc). L'INA, par exemple, a procédé par expertise pour identifier les 14.000 sites média de son périmètre d'archivage.

Lors d'une collecte plus large, les archivistes peuvent s'appuyer sur des indices traduisant la valeur d'un site ou d'une page visitée. Le degré d'un site Web (Figure 3.6) permet ainsi d'estimer son autorité au

<sup>30</sup> Nous discuterons plus en détail de cette problématique dans le Chapitre 6

<sup>31</sup> Dans un script cherchant à sélectionner les sites du domaine français, on ne conservera que les noms de domaine dont l'extension valide l'expression régulière suivante : `*.fr$`




Figure 3.6: Graphe dont les nœuds sont labellisés par degré. En théorie des graphes, le degré  $\deg(v)$  d'un nœud  $v$  correspond au nombre de liens incidents (entrant ou sortant) à ce nœud.

sein d'un environnement hypertexte (Abiteboul et al., 2002). Une autre stratégie consiste à identifier les sites sources par rapport aux habitudes de navigation des internautes. Quels sites sont fréquemment visités ? Quelles pages en particulier ? Il s'agit alors d'exploiter les requêtes adressées à un moteur de recherche en ligne (Pandey and Olston, 2005). Ou encore, de se baser sur les *access patterns* (AlNoamany et al., 2013) afin de privilégier, au sein d'un même site, l'archivage de séquences de pages fréquemment visitées. Le système de sélection d'Internet Archives, en particulier, utilise cette dernière méthode (Kimpton and Ubois, 2006). Dans la même veine, un historique de navigation personnel pourra faire office de liste de primo-candidats à archiver (Dumais et al., 2016). Cette fonctionnalité a récemment été ajoutée aux archives du Web danois<sup>32</sup>. Mais précisons, qu'aucune stratégie de sélection ne prévaut sur une autre. Elles sont d'ailleurs souvent combinées pour former une chaîne complexe en amont de tout collectage (Section 3.3).

<sup>32</sup> Une version bêta du système danois est disponible ici : <https://github.com/netarchivesuite/solrwayback>

Par ailleurs, il est possible d'opérer une sélection par *crowd sourcing* en faisant appel à des archivistes tiers. C'est toute l'idée du service payant *Archive-it*<sup>33</sup>, lancé en 2006 par Internet Archive, permettant à tout un chacun de se constituer des corpus d'archives Web. Quelques 230 millions d'URLs ont ainsi été recueillies entre 2006 et 2007 avant d'être reversées dans le fond d'archives principales de la Wayback Machine. Dans l'idée de démocratiser encore d'avantage leur exploitation, les archives portugaises offrent la possibilité à chaque internautes de suggérer une liste de pages ou de sites Web (pas nécessairement appartenant au domaine portugais .pt) à ajouter aux collectages<sup>34</sup>. L'utilisateur devient ainsi acteur de la préservation du Web.

<sup>33</sup> <http://www.archive-it.org>

<sup>34</sup> <http://sobre.arquivo.pt/en/collaborate/suggest/>

Terminons en soulignant que le choix d'archiver une page plutôt que l'ensemble d'un site (et inversement) n'est pas trivial. À quelle échelle doit-on archiver ? L'arbitrage est souvent décidé au cas par cas et peut faire l'objet de compromis. Même si l'on demande à Internet Archive de sauvegarder une page précise, le système remontera toujours à la front page du site afin d'en archiver la racine (Kimpton and Ubois, 2006). Ce genre de mécanisme permet d'amender et d'enrichir les points d'entrées après chaque collecte. La découverte de nouveaux sites appelant à réévaluer sans cesse la liste d'origine.

### Collecte

Par **collecte** nous désignons l'ensemble des techniques visant à transformer une page du Web vivant en une page archivée. Comme nous l'indiquions précédemment le Web peut, sous certains aspects, être considéré comme *self preserving*. Une fois archivés, l'ensemble des éléments collectés restent accessible depuis le Web. Le Web contient en

lui même les traces de son passé. Lorsque l'on scanne une pellicule, image par image pour archiver un film, on fait subir à ce support de mémoire une transformation. De l'analogique au numérique. Dans le cas d'une ressource Web, la transformation induite par la collecte est minime. Il s'agit grossièrement de venir prélever les fichiers d'origines d'une page, sans les altérer et de les dater avant de les réintroduire dans les archives Web.

Or, le protocole HTTP qui régit les règles de communication sur le Web, entre client (l'internaute) et serveur (la page), n'autorise qu'un accès unitaire aux ressources Web. Il n'est possible d'accéder au Web qu'une page à la fois. La page Web (identifiée par une URL unique) est en cela l'unité de consultation de base du Web. La collecte doit donc s'effectuer page après page et non par lot, telle que :

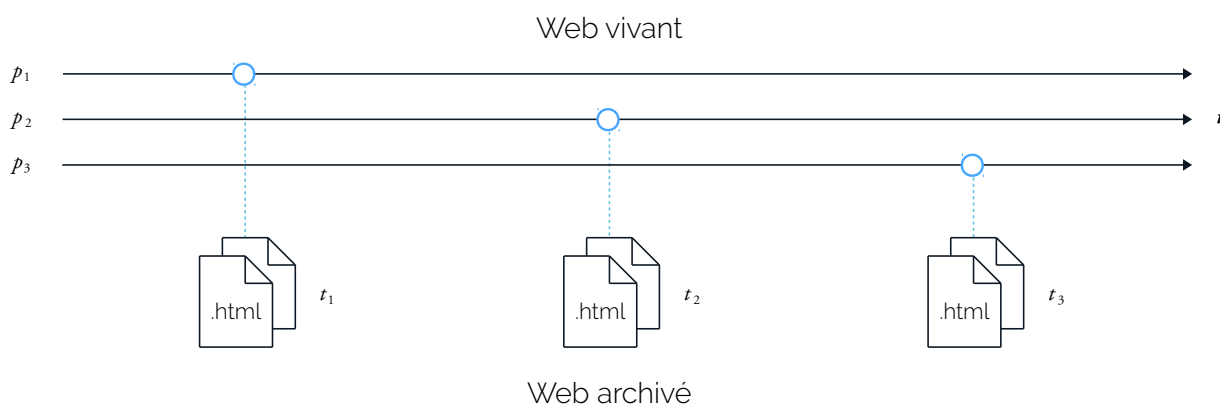


Figure 3.7: Archivage du Web vivant page après page, de  $p_1$  à  $p_3$

Il existe ainsi trois grandes familles de techniques d'archivage du Web, qui témoignent du déplacement progressif des outils de collecte du serveur vers le client.

La première, nommée *serveur-side-archiving*, consiste à collecter les ressources directement depuis le serveur hébergeant un site ou une page Web. Cette technique est plutôt employée par les producteurs de données eux même, s'ils souhaitent archiver l'ensemble des ressources d'une de leur plateforme Web par exemple. Mais les moyens à mettre en place sont considérables car, à la différence d'une simple copie, le *serveur-side-archiving* induit la réplication du site (les fichiers HTML, CSS, etc d'origine) et de l'entièreté de son environnement de développement et d'hébergement. On utilisera plutôt cette méthode pour archiver le Web dit profond<sup>35</sup>.

La seconde approche, dite *transaction-archiving*, se situe à la frontière entre serveur et client. Il s'agit ici de positionner l'outil de collecte au niveau du système d'entrées/sorties (IO) du serveur hébergeant le site

<sup>35</sup> À opposer à la portion visible du Web (ce que l'on voit derrière son écran), le Web profond désigne tout élément qui n'est pas accessible directement depuis un crawler : les formulaires, bases de données, etc (Lawrence and Giles, 2000). Une discussion sur l'exploration d'archives du Web profond sera menée au chapitre 7

<sup>36</sup> Ce type d'archive fera l'objet d'une exploration dédiée au chapitre 7, où nous interrogerons les logs de navigation Web de la Bibliothèque du Centre Pompidou

<sup>37</sup> Ce manuscrit n'étant pas spécifiquement centré sur la question des crawlers, il est possible d'en apprendre d'avantage en se référant aux cours de C. Maussang (<https://frama.link/FrFrZ5EC>) ou en se tournant vers des ouvrages dédiés (Chakravarthy et al., 2002; Mitchell, 2015)

Web ciblé (Fitch, 2003). Ce que l'on archivera sera le couple [requête, réponse] du client au serveur, soit la demande d'un internaute cherchant à visiter une URL donnée et la page Web telle que retournée par le serveur. Cette forme d'archive dessine une vision non exhaustive d'un site Web mais néanmoins fidèle à la réalité du flot d'internautes qui le parcourent. En capturant la trace des pages effectivement visitées et la manière toujours unique dont celles-ci sont affichées à l'écran des utilisateurs, cette technique est la seule qui intègre directement l'humain et ses gestes dans les archives Web<sup>36</sup>.

La dernière famille, connue sous l'appellation de *client-side-archiving*, est aussi la plus rependue. Ayant acté qu'une ressource Web pouvait être visualisée d'une infinité de manière possible par le client (l'internaute), l'archiviste choisit ici de placer son outil de collecte en lieu et place de l'utilisateur. L'outil devient client et cherche à reproduire les interactions d'un internaute pour accéder au contenu ciblé : la page Web à archiver. Tout l'enjeu est donc de définir et de contrôler l'exhaustivité de ces interactions pour construire une copie fidèle d'une page ou d'un site.

Comme la collecte doit être menée page par page, programmée à l'avance et conduite à échelle large, les archivistes du Web se sont inspirés des *crawlers* développés pour les moteurs de recherche (Pant et al., 2004) à la fin des années 1990. Un **crawler** est un robot programmé pour parcourir un site ou un ensemble de sites, une page à la fois, en capturant au passage l'ensemble de ses fichiers d'origine. Un crawler, pour bien fonctionner, doit respecter des règles de politesse : éviter les dénis de services (DNS, Serveurs HTTP), les blacklistages officiels (robots.txt, sitemap.xml, etc.) et officieux (*cloaking*, pièges à robot)<sup>37</sup>. Dans le cadre spécifique des archives du Web, un crawler doit en plus intégrer les contraintes temporelles évoquées précédemment. Il a pour mission de capter l'ensemble des changements intervenants sur une page ou un site cible. Enfin, nous appelons **crawl** une campagne d'archivage menée par un crawler et (par abus de langage) le résultat même de cette campagne.

L'aspect d'un corpus d'archives Web est directement le fait du crawler qui a mené la collecte. Un crawl peut ainsi être conduit de plusieurs manières. Une première possibilité revient à entreprendre une collecte en profondeur d'abord (*depth-first*, Figure 3.8 (a)). Le crawler capturera en priorité les pages filles de la page sur laquelle il se trouve. Un autre approche consiste à travailler en largeur d'abord (*breadth-first*, Figure 3.8 (b)). Le crawler privilégiera cette fois les pages sœurs. Mais ces techniques sont lentes et il faudra prévoir un temps considérable pour parcourir l'entièreté d'un site, or l'archiviste cherchera au contraire à minimiser le temps de capture. Aussi, on peut envisager l'instauration d'une limite en profondeur pour ne pas archiver des






Figure 3.8: Différentes stratégies adoptées par un crawler  $c$  pour collecter les pages  $\{p_1, \dots, p_n\}$  d'un même site

pages trop éloignées de la racine du site (Figure 3.8 (c)).

En pratique, l'archiviste optera plutôt pour un compromis entre largeur et profondeur. Avec la démocratisation des moteurs de recherches en ligne, l'internaute n'est plus obligé de passer par la front page d'un site pour en consulter le contenu. Les profils de navigation se diversifient rapidement (Hölscher and Strube, 2000). Pour identifier les pages pertinentes, les crawler doivent donc intégrer à leurs programmations divers indicateurs topologiques ou sémantiques. Le pageRank (Page et al., 1999) ou le degré entrant d'un site (Figure 3.9) traduisent tous deux l'importance d'une page crawlée (Cho et al., 1998). Ces mesures peuvent être enrichie au regard de l'historique du crawl ou d'une possible hiérarchie entre pages (Baeza-Yates et al., 2005).

Nous le verrons, lorsque dans la chapitre 4 nous changerons de point de vue, passant de l'archiviste à l'explorateur d'archives, la cohérence est une notion fondamentale. Un crawl doit garantir une forme de cohérence topographique et temporelle vis à vis du corpus qu'il cherche à constituer. Sur ce point, il faudra poser la question de l'ordonnancement des sites les uns par rapport aux autres. Certains sites, larges ou volatiles, feront l'objet d'une collecte rapide (*short-term scheduling*) qui mobilisera toutes les ressources du crawler. Pour les autres, le crawl s'inscrira dans le temps long (*long-term scheduling*) et pourra prendre plusieurs jours (Castillo et al., 2004). Ne crawler que lorsque qu'un site est le moins susceptible de subir des changement peut aussi garantir une cohésion temporel au corpus (Saad et al., 2011). S'appuyant sur toutes ces réflexions, les équipes d'Internet Archive présentent en 2004 un crawler open-source, l'Heritrix (Mohr et al., 2004) capable de s'adapter à divers type de collecte : large (*broad*




Figure 3.9: Graphe dont les nœuds sont labellisés par degré entrant. En théorie des graphes, le degré  $\deg^-(v)$  d'un nœud  $v$  correspond au nombre de liens incidents entrant à ce nœud.

*crawling*), en continue (*continuous crawling*) ou focalisée (*focused crawling*). Heritrix reste encore aujourd'hui le crawler le plus répandu pour l'archivage du Web.

Face à l'évolution du Web, les crawler s'adaptent et archivent de nouveaux objets : allant des sites Flash<sup>38</sup> aux vidéos Youtube ou Dailymotion (Pop et al., 2010). Mais alors que les contenus publiés incorporent de plus en plus d'éléments dynamiques, se syndiquer à un flux RSS devient une stratégie à part entière pour collecter de l'information en continue (Oita and Senellart, 2010). Des bibliothèques sont développées pour interpréter les portions de code utilisant du Javascript<sup>39</sup> et les crawlers commencent à se spécialiser pour archiver certains réseaux sociaux. Les interfaces de programmation applicative (API) s'imposent comme des sources de données auxquelles il convient de se connecter. Si certaines APIs ouvertes permettent de crawler l'entièreté d'une plateforme<sup>40</sup>, d'autres plus limitées obligent les archivistes à faire preuve d'inventivité. Ainsi, Internet Archive possède, depuis Mars 2016, un compte Facebook *charlie.archivist* dont la timeline est régulièrement archivée<sup>41</sup>.

Terminons ce descriptif des techniques de collecte, par une présentation plus poussée du crawler de l'INA. Développé par les équipes de T. Drugeon (Drugeon, 2005), ce crawler fut en charge (de 2010 à 2014) de l'archivage des sites Web de l'Atlas e-Diasporas.

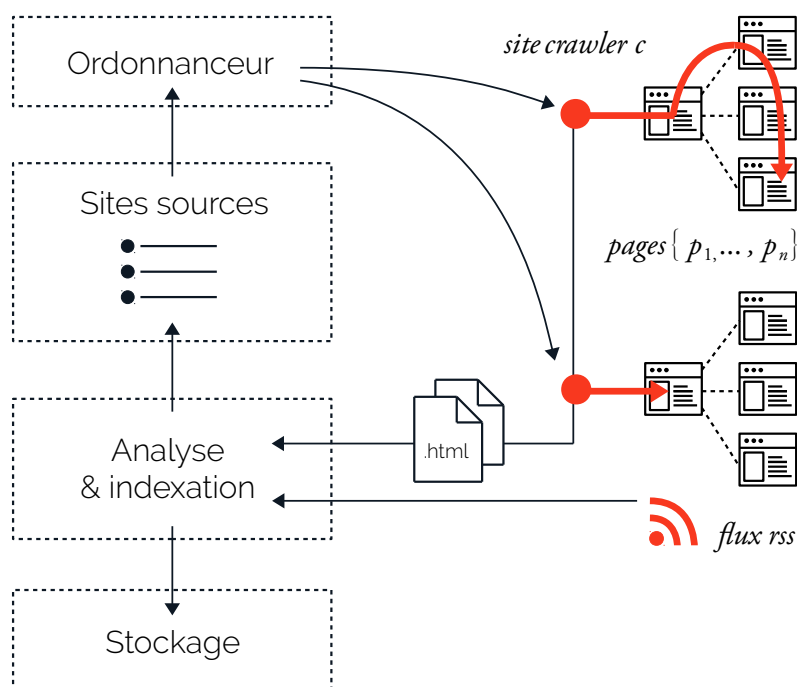
<sup>38</sup> [https://fr.wikipedia.org/wiki/Adobe\\_Flash](https://fr.wikipedia.org/wiki/Adobe_Flash)

<sup>39</sup> <https://github.com/ariya/phantomjs>

<sup>40</sup> Voir la crawl de Github réalisé en 2010 par F. Cuny et Linkfluence (<http://www.visualcomplexity.com/vc/project.cfm?id=785>)

<sup>41</sup> <https://web.archive.org/web/20170914234842/https://www.facebook.com/charlie.archivist>

Figure 3.10: Fonctionnement général du système de collecte de l'INA



Pour commencer (Figure 3.10), un ordonnanceur général (*scheduler*) gère la liste des sites sources auxquels une fréquence de collecte a été associée. En se basant sur cette fréquence, l'ordonnanceur choisit les sites à archiver en priorité et leur dédie à chacun un crawler (*site crawler*). Plusieurs centaines de crawlers peuvent être ainsi lancés en parallèle. Ces crawlers procèdent à une récolte en largeur d'abord, mais sans sortir du périmètre du site qui leur est alloué. Une fois les pages visitées, le contenu est indexé et stocké sur fichiers. À ce niveau, si des liens hypertextes sortants sont détectés dans une page, les sites pointés par ces derniers sont conservés afin de potentiellement venir enrichir la liste des sites sources. La fréquence de collecte est mise à jour entre deux crawls successifs. Soit en analysant les informations venues de l'agrégateur de flux RSS, soit en comparant l'évolution d'une page archivée d'une version à l'autre. Cette architecture, fait du crawler de l'INA un outil extrêmement réactif, adapté à la nature même des sites médias et, de fait, très efficace lorsqu'il s'agit de constituer rapidement des corpus portant sur un événement singulier<sup>42</sup>.

<sup>42</sup> Voir la collecte réalisée pour les attentats de Paris en 2015 (<https://asap.hypotheses.org/173>)

### Stockage

Le **stockage** représente l'ensemble des techniques d'enregistrement d'une ressource Web crawlée. Ainsi, parallèlement à son crawler, l'INA développe son propre format de fichier destiné au stockage des archives Web : le Digital Archive File Format (DAFF). L'INA prend ainsi le contre pied du reste de la communauté qui, elle, continue de s'en tenir au format Web ARChive (WARC) pour sauvegarder la grande majorité des corpus existants.

C'est en 1996, s'inspirant du format de compression et d'archivage ARC (popularisé à la fin des années 80), qu'Internet Archive définit le ARC\_IA<sup>43</sup>. L'idée étant de combiner plusieurs ressources collectées en un seul et même fichier avant de les compresser pour en réduire la taille sur disque.

<sup>43</sup> <https://www.loc.gov/preservation/digital/formats/fdd/fdd000235.shtml>

Mais l'ARC\_IA évolue rapidement, suivant les avancées des techniques de crawl, et ce, jusqu'à atteindre sa version actuelle : le WARC. Devenu le format standard d'archivage Web en 2009<sup>44</sup>, un fichier d'archives WARC peut être vu comme la concaténation de plusieurs enregistrements (ou blocs), chaque enregistrement correspondant à une ressource Web crawlée<sup>45</sup>. Les informations contenues dans un bloc WARC sont de deux natures : des *meta données* et des *données*. Les méta données (stockées dans le *header* du bloc) couvrent toutes les informations relatives au crawl : date de collecte, taille de la ressource, URL de la ressource, ID du bloc, ... Ces méta données sont directement suivies des données à proprement parler : soit l'enregistrement brut

<sup>44</sup> <https://www.iso.org/standard/44717.html>

<sup>45</sup> Une page, une image, ... Chez Internet Archive, tout objet associé à une URL unique sera archivé comme ressource Web

des fichiers .HTML, .CSS, etc collectés. Ainsi, chaque fois qu’une page Web est archivée (qu’elle ait évolué ou non depuis le précédent crawl) un bloc est ajouté au fichier WARC courant (Figure 3.11 (a)).

Directement liés au WARC, il est possible d’extraire d’un bloc deux sous-formats spécialement dédiés à l’exploitation des corpus : les WAT et WET. Un fichier WAT (Web Archive Transformation) ne contient que des méta données. Contrairement au WET (Web Extracted Text) et à ses dérivés (LGA ou WANE<sup>46</sup>) qui, eux, ne stockent que des éléments de texte issus de la partie données d’un bloc WARC. Ces fichiers WAT et WET répondent à l’une des principales critiques lancées à l’encontre du format WARC, pourtant hégémonique : le WARC introduit de la redondance dans les stocks d’archives Web.

En effet, entre deux crawls successifs, un bloc WARC sera invariablement créé (que la ressource Web collectée ait évolué ou non). Une page Web stable dans le temps, verra ainsi son contenu archivé autant de fois qu’elle aura été crawlée, conduisant à une consommation d’espace de stockage considérable. C’est donc en partant de l’intuition selon laquelle méta données et données devraient être stockées séparément (pour ne pas surcharger les corpus) que l’INA a développé le format DAFF.

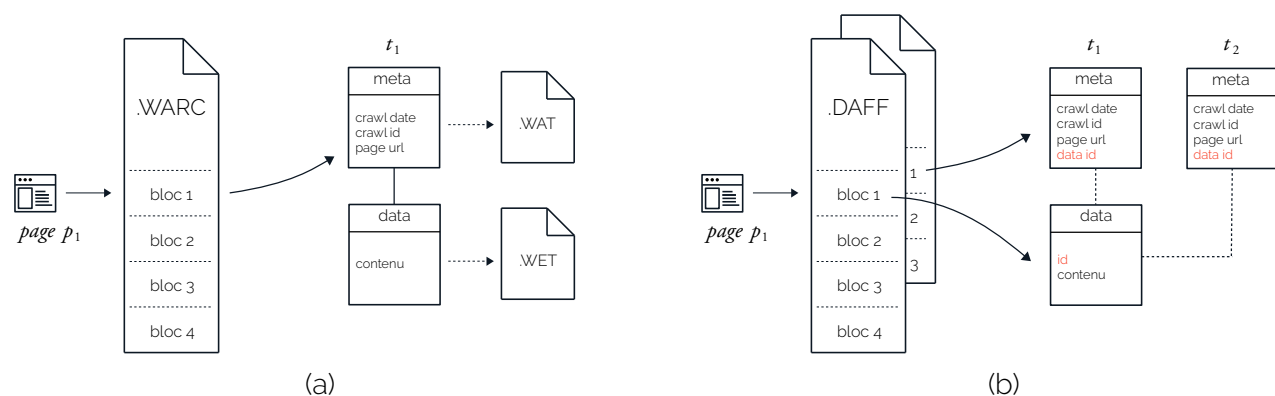


Figure 3.11: Différences entre les formats WARC (a) et DAFF (b)

Une archive DAFF est en réalité l’association de deux fichiers complémentaires : un fichier de méta données et un fichier de données. Comme pour le WARC, chaque fichier est une suite de blocs correspondant à une ressource Web crawlée. Le fichier de méta données contient divers champs relatifs à la collecte (voir Table 3.1). Le fichier de données, quant à lui, ne renferme que deux champs : un identifiant unique et le contenu (HTML, CSS, etc) de la page Web archivée. Avec le DAFF, données et méta données sont stockées séparément. Ainsi, d’un crawl à l’autre, si la page Web visitée n’a pas évolué, alors son

<sup>46</sup> <https://webarchive.jira.com/wiki/spaces/ARS/pages/90997507/Datasets+Available>

contenu ne sera pas re-téléchargé : seul un nouveau bloc de méta données sera ajouté pour témoigner du passage du crawler. Chaque bloc de données est donc associé à un ou plusieurs blocs de méta données (le champ *content* des méta données correspondant au champ *id* des données). Ce mécanisme permet, d'une part de ne pas dupliquer inutilement le contenu d'une page Web archivée et, d'autre part, de pouvoir pratiquer rapidement divers calculs statistiques sur le seul fichier de méta données. Celui étant pas nature plus léger qu'un WARC complet, donc moins long à traiter.

Notons que pour tester si une page a évolué depuis sa précédente visite, le crawler de l'INA compare la valeur des champs *id* des blocs de données concernés. En effet l'*id* est une clé SHA-256 résultant du hachage<sup>47</sup> du contenu même de la page Web archivée. On dira donc d'une page Web qu'elle s'est transformée si et seulement si les deux clés successives sont différentes. La nature de ce changement ne sera en revanche pas connue, celui-ci pouvant aller de la refonte entière de la page à la simple suppression d'une virgule.

<sup>47</sup> En cryptographie, le hachage consiste à une donnée de taille arbitraire, une image (ou clé) de taille fixe et unique

Méta données	Champ	Description
<i>obligatoire</i> {	id	identifiant unique du bloc
	url	url associée à la ressource
	date	date de téléchargement (Timesone GMT, ISO 8601)
	content	identifiant unique du bloc de données associé
	status	statut de retour du crawler (ok, request_error, server_error, etc)
<i>facultatif</i> {	crawl_session	identifiant unique de la campagne de crawl
	charset	encodage de la ressource
	type	MIME Type (identifiant du format de donnée de la ressource)
	corpus	nom du corpus d'archives associé
	ip	adresse ip associée au crawl
	level	profondeur du crawl
	page	la ressource est elle une page Web (0   1)
	client_country	nationalité associée à la page
	length	taille du bloc de données associé
	active	la ressource était elle active au moment du crawl
	client_lang	langue associée à la ressource
	referer_url	url précédemment visitée par le crawler
Données	Champ	Description
	id	clé SHA-256 unique
	content	contenu (HTML, CSS, etc) de la ressource

Outre le stockage sous formats WARC et DAFF, J. Masanès (Masanès, 2006) rappelle qu'il existe des méthodes alternatives de sauvegarde

Table 3.1: Ensemble des champs disponibles dans les fichiers de méta données et de données DAFF

des archives. Associées aux stratégies de collecte situées côté serveur (*serveur-side-archiving*) on trouvera les formes dites de *local file system served archives* qui consistent à transformer un site Web archivé en une copie locale de l'ensemble de ses ressources. Ainsi les URIs absolues, permettant (sur le Web) de naviguer d'une page à l'autre, seront transformées en URIs relatives à l'intérieur du fac-similé. Très couteuse, cette méthode nécessite de transformer en profondeur la nature des pages archivées et devient vite ingérable à mesure qu'augmente le nombre de collectes.

Enfin, il reste toujours possible de copier un site, page après page, sous format PDF ou image (capture d'écran ou vidéo). Bien que facile à mettre en place (techniquement parlant) cette stratégie ne passera pas non plus à l'échelle<sup>48</sup> et aura pour conséquence d'arracher les sites et pages Web archivés à leur environnement hypertexte d'origine.

<sup>48</sup> En 2013, K. Goldsmith imprime littéralement plusieurs centaines de milliers de pages Web en soutient à A. Schwartz, remplissant l'équivalent d'une pièce de 1,100 m<sup>2</sup>

Pour terminer, les corpus d'archives Web répartis dans le monde se comptent par centaines. Alors que le Web vivant continue son expansion, le volume du Web archivé ne cesse de croître. En 2017, la BnF avait archivé 18,000 millions de pages Web (soit environ 370TB) tandis que l'INA plafonnait à 43,000 millions de pages pour un total avoisinant les 420TB. Et depuis sa création, l'Internet Archive a collecté à elle seule pas moins de 650,000 millions de ressources Web soit 40,000TB de données. Ainsi, face à ces corpus qui s'amassent et à la nécessité de les exploiter, les archiviste du Web ont du développer des outils dédiés à leur exploration.

### Fouille

There are 21 initiatives (50%) that provide full online access to search mechanisms. Some initiatives hold the copyright of the archived contents (e.g. German Bundestag, UK WA, Canada WA). The Internet Archive and the Portuguese WA proactively archive and provide access to contents but remove access on-demand. On the other hand, for 16 initiatives (38%) the access to the collections is somehow restricted. The Library of Congress, WebArchiv and Australia's WA provide public online access to part of their collections. BnF, Web@rchive and Preservation .ES grant access exclusively through special rooms on their facilities.

The Archive-Access tools are dominant (62%), including the Heritrix, NutchWAX and Wayback projects,

Nonetheless, NutchWAX supports full-text search for the Finnish WA (148 million), Canada WA (170 million), Digital Heritage of Catalonia (200 million), California Digital Library (216 million) and BnF (estimated 2 100 million). Australia's WA supports full-text search over 3 100 million contents indexed using an in-house developed system

named Trove. I

Even with the high computational resources required for this purpose, 67search for at least a part of their collections [14]. In another survey about European web archives this percentage is 70[13].

The Living Web Archives (LiWA) aimed to provide contributions to make archived information accessible [19]. It addressed problems shared with other information retrieval (IR) areas, such as web spam detection, terminology evolution, capture of stream video, and assuring temporal coherence of archived content. LiWA was followed by the Longitudinal Analytics of Web Archive data (LAWA), which aims to build an experimental testbed for large-scale data analytics [28].

!!! aussi de dire que Internet Archives bouge ces data storage pour les garder à l'abri

ha et là je parle de comment on fait des analyses on top of web archives

et on se dit que tout de même ça ressemble un peu à une capsule temporelle que l'on regardera plus tard là placer la ref aux capsules tempo

### 3.3 Les archives Web de l'Atlas e-Diasporas

Présentation rapide de l'ensemble des corpus et focus sur les Marocains (explication ...)





# | Traces Discrétisées et Temporalité Figée

## 4.1 Détruire pour mieux archiver

on parle en fait de pages depuis alta vista The launch of the AltaVista service in December, 1995 proved that all of the pages on the Web could be treated as a single collection, and indexed and made searchable for all users on the Net.

De Derrida aux traces discrétisées, de la sélection effectuée par le crawler et l'archiviste, les archives sont des traces discrètes du Web, comme Funes on ne peut tout garder

## 4.2 Un temps sans extension

Bon idéalement l'archive devrait être iso au site, mais ce n'est plu le web cf brugger Mais en fait on transforme le site pour l'archiver : re-creation of the Web information system

Ici on part de Saint Augustin et de sa définition d'un présent sans extension qui a influencer le rapport des occidentaux au temps. Ce rapport au temps se retrouve lorsque l'on étudie en détail les modèles d'exploration des archives web qui s'appuient sur la date de capture d'un contenu. S'en suit plusieurs remarques qu'il faut conserver en tete avant de se plonger dans toute exploration

proposer ici une échelle de datation (date de téléchargement et date de last modified)

Niveau	Nature de la date
page	téléchargement
page	dernière modification

↓ Validité historique

Table 4.1: Échelle de datation d'une page Web archivée



Figure 4.1: "Boulevard du Temple",  
Louis Daguerre, 1838

Figure 4.2: Warc vs Daff

*Crawl blindness*

*Cohérence*

*Duplicata*

### 4.3 Construire un moteur d'exploration d'archive

*Extraction et enrichissement*

*Définition du schéma d'indexation*

bon y'a déjà des travaux

Web archives receive a significant number of queries with a specific time interval of interest, denoted time-travel queries "Characterizing search behavior in web archives". Thus, partitioning the index by time enables searching only the sub-index corresponding to that interval.

In this work, we refer to the time when the web documents were crawled, but we could use other time attributes associated to documents, such as their creation or publication dates. Some works use instead the time mentioned on the document text "On the value of temporal information in information retrieval".

We can have at least four types of partitions, where the index is split per time and then per document or term, or the opposite.

When partitioning first by document and then by time, subsets of documents are allocated to computer clusters according to their identifiers "A time machine for text search"

Les gars préfèrent rester à la page The document-based partition of the index offers superior query throughput and does not require rebuilding of the indexes each time new documents are indexed, contrary to the term-based partition.

moi je vais en dessous

Alternatives for rebuilding the indexes when using the term-based partition exist, but are also more complex and less efficient than using the document-based partition "Index maintenance for time-travel text search".

The open source Wayback Machine (WM) is a set of loosely coupled modules that can be exchanged and configured according to the web archive needs "Wayback' for Accessing Web Archives"

The Internet Archive's WM uses as index a flat file sorted alphabetically by URL and divided in similar size buckets. The buckets are distributed across web servers and map URLs to the ARC files storing them [10]. Thus, each web server responds over a subset of documents (i.e. URLs), meaning that this architecture uses a document-based index partition. When the WM receives a URL query, a broker routes

it to the web server handling that range of URLs, which replies with the list of all URL versions. To access one of these versions, the web server replies with the respective ARC name. Then, the ARC file is located by sending a UDP broadcast to all storage servers. There are more than 2500 storage servers in the primary data center, each with up to four commodity disks. The storage server containing the ARC file replies to the broadcast with the local file path and its identification. Finally, the client browser is redirected to the respective storage server, which runs a lightweight web server to deliver the ARC file. The Portuguese Web Archive (PWA) <http://archive.pt> is based on the WM, but uses NutchWAX as its full-text and URL search engine "Introducing the Portuguese web archive initiative."

NutchWax est un search basé sur lucene mais adapté pour bouffer du WARC "Full text searching of web archive collections." qui travaille sur une indexation à la page puis sur un bucket of time

Il y a d'autre search qui font du solr pur au lieu de Nutch "A survey on web archiving initiatives" Everlast est un système de search en peer to peer ça partitionne par terme puis par time "EverLast: a distributed architecture for preserving the web."

à la bpi c'est du elasticsearch

#### *Détection d'événements*

### **4.4 Les archives sont des traces indirectes du Web**

Les archives sont les traces directes du crawler et non du web (Cf mises en garde précédentes) + exemple sur yabiladi.com donc il faut descendre au niveau de la page et y extraire d'autres temporalités, d'autres formes d'exploration qui ne dépendent pas non plus de la linéarité proposée par les moteurs d'exploration classique. La désagrégation se fait dans le modèle de données mais également dans la façon de conduire l'exploration.

## | Fragmenter les Archives Web

Les effets de crawl legacy (Section 4.4) sont indissociables des archives Web telles que nous les connaissons. Liés organiquement à la structure même des fichiers archivés (Figure 4.2), ils en sont les artéfacts directs. Pour qui souhaite conduire l'analyse d'un ensemble de sites Web archivés, ces effets induisent nombres d'obstacles : collectage non régulier, sur-représentation de certaines parties d'un site, incohérences entre contenus archivés, etc. Lors de la consultation des archives, l'explorateur n'a que très rarement la main sur les commandes du crawler et doit se contenter de l'état du corpus qui lui est proposé.

Nos travaux portant sur l'exploration de corpus d'archives Web déjà existants et/ou constitués de longue date, nous ne proposerons pas ici d'alternative aux formats WARC et DAFF. Nous chercherons plutôt à définir une stratégie d'exploration capable de s'affranchir de l'héritage pesant des crawlers sur les archives Web ou tout au moins d'en atténuer les effets. Il faut également préciser que nous conditionnons notre réflexion à la réalisation d'une exploration large (en terme de pages à visiter) et profonde (en terme de durée à parcourir) des archives Web qui implique le développement d'une méthodologie dédiée à une échelle si large (Chapitre 6). Il va sans dire, que pour l'étude à la main d'une poignée de sites ou de pages (depuis la WayBack Machine par exemple), les effets de crawl legacy restent parfaitement surmontables. En revanche, cette tâche devient rapidement fastidieuse voire titanique à mesure que grandit le périmètre d'exploration et que la validation humaine s'efface au profit d'un algorithme ou d'un ensemble de scripts.

Sur ce point, nous proposerons l'introduction d'une nouvelle unité d'exploration des archives Web : le **fragment Web**. L'essentiel de ce chapitre sera consacré à expliciter l'intuition selon laquelle il peut être bénéfique de descendre au delà du niveau des pages Web archivées en proposant un changement d'échelle analytique. Le fragment Web devra d'une part offrir aux explorateurs du Web passé une plus grande souplesse et de nouveaux outils pour déconstruire, recomposer et questions les archives, et d'autre part, cette unité devra devenir un objet

d'étude à part entière. Plutôt que d'être une trace directe du crawler, le fragment Web cherchera à témoigner des gestes de l'auteur ou du lecteur d'un site archivé dont le passages parmi ses pages aura laissé des indices qu'il nous faudra exploiter. Nous nous concentrerons particulièrement sur la question de la bonne datation d'une page Web archivée en nous basant sur les dates de création et d'édition de tel ou tel contenu. En associant le fragment Web à une date d'édition nous discuterons du changement de temporalité ainsi constaté : passant du crawler à la page Web et ses fragments. Nous en illustrerons ensuite le bénéfice potentiel en terme de précision historique. Enfin, nous reviendrons en miroir sur les modalités techniques et théoriques d'un moteur d'exploration d'archives Web (Chapitre 4) prenant dès à présent le fragment Web comme unité principale d'indexation. Une démonstration en sera donnée via un cas simple de détection d'événements parmi le contenu fragmenté des archives de *yabiladi.com*.

Tout au long de ce chapitre, nous appuierons nos réflexions sur les travaux de l'historien du Web N. Brügger et sur la notion de *strates analytiques du Web* qui servira de cadre à la définition de nos propres fragments Web. La question du changement de temporalité sera, quant à elle, abordée à l'aune des recherches de l'historien médiéviste J. Baschet sur les enjeux historiographiques d'un tel déplacement.

## 5.1 Vers une nouvelle unité d'exploration

Toute archive est une matière destinée à être désagrégée ou ré-arrangée en vue de la questionner et d'écrire l'histoire. Ainsi le professeur d'archivistique E. Ketelaar dit d'une archive qu'elle ne parle pas seule (Ketelaar, 2006), qu'elle n'est jamais fermée ou complète. Une archive se tient toujours prête à être réinterprétée par une nouvelle génération d'explorateur ou de chercheur. Mais s'il est clair que la direction prise avec l'introduction du fragment Web est celle d'une déconstruction des corpus d'archives Web existants, gardons à l'esprit comme le rappelle Derrida<sup>1</sup>, que le document d'origine ne doit en aucun cas être altéré ou modifié. Et ce, pour justement permettre à d'autres, après nous, d'à nouveau s'y référer, le faire parler.

Précisons donc avant toute chose, que le fragment Web, ne sera pas une version modifiée d'une page Web archivée et de ses fichiers sources, mais bien une entité autre, issue du fractionnement de cette page et utilisable en parallèles des modèles d'exploration d'archives déjà existants.

<sup>1</sup> "je peux interroger, contredire, attaquer ou simplement déconstruire une logique du texte venu avant moi, devant moi, mais je ne peux ni ne dois le changer", (Derrida, 1995), p.374.

### *Découper, déplacer, monter*

Nous évoquions déjà dans la section 4.1 le personnage de Funes imaginé par Borges qui, dans la fable, à force de ne plus jamais rien oublier, voyait décroître ses capacités à penser et à raisonner. Funes vit dans l'indexation d'un perpétuel présent. Il se redécouvre sans cesse et n'arrive plus à se recréer des souvenirs, à se raconter de mémoire sa propre histoire<sup>2</sup>.

Pour mémoriser ou archiver il faut oublier. Ré-arranger et faire du montage. Nos souvenirs sont des sélections qui, mises bout à bout, collées, accélérées ou ralenties forment le fil de nos histoires. Le cinéaste C. Marker donne corps à cette idée dans son film d'archives *"Le Fond de l'Air est Rouge"*<sup>3</sup> où la posture de l'historien face à un document archivé se rapproche de celle du monteur de cinéma face à une matière filmée. Leurs outils sont semblables. Lorsqu'il invente l'histoire, l'historien découpe, isole et rapproche des sources archivées potentiellement très éloignées.

Dans son court métrage *"Je Vous Salue, Sarajevo"*, réalisé en 1993 pendant la Guerre de Bosnie-Herzégovine<sup>4</sup>, J.L. Godard déconstruit une photographie du reporteur de guerre R. Haviv. Il fragmente et fait se confronter des inserts éclatés à la manière d'un collage-poème ou d'un cinétract<sup>5</sup>. Par le collage, les fondus et les découpages Godard rompt la continuité de l'archive qu'il utilise comme source première afin de rendre compte image après image de la cruauté qui frappe Sarajevo, une ville de son temps (Figure 5.1). Le film finit par dévoiler entière, l'image dans toute son horreur. Décomposer pour mieux recomposer.

<sup>2</sup> "[Funes], ne l'oublions pas, était presque incapable d'idées générales, platoniques. Son propre visage dans la glace, ses propres mains, le surprenaient chaque fois.", (Borges, 1974), p.??.

<sup>3</sup> Film réalisé en 1977. C. Marker superpose par exemple aux souvenirs de S. Signoret des extraits remontés et recolorisés du *"Cuirassé Potemkine"* d'Eisenstein (<https://youtu.be/d01E4GYjF1s>)

<sup>4</sup> Voir <https://youtu.be/WKbfu8rRrho>

<sup>5</sup> Mini-films non signés à caractère militant, réalisés en mai et juin 1968 (<https://fr.wikipedia.org/wiki/Cin%C3%A9tract>)



Figure 5.1: Extraits de *"Je Vous Salue, Sarajevo"*, J.L. Godard (1993) à partir d'une photographie de R. Haviv (1992)

Il y a dans les travaux de Godard et de Marker une souplesse d'action vis à des archives à même de se révéler profitable si nous l'appliquions aux archives Web. Chercher à avoir en main des éléments fragmentés de pages Web éloignées, que nous pourrions associer, à souhait, afin de traiter plus largement d'un moment particulier de l'histoire du Web. Comment se donner la possibilité de rapprocher automatiquement deux contenus archivés hors du carcans de leurs pages respectives ? Peut-on par exemple demander à un moteur d'exploration d'archives de nous retourner l'ensemble des messages postés sur un forum, par une seule et même personne il y a dix ans de cela ?

### *Les strates analytiques du Web*

Le glissement d'un niveau d'analyse à un autre, vers un en-dessous de la page archivée, est formulé pour la première fois par l'historien du Web N. Brügger lorsque, cherchant à définir le site Web comme objet potentiel de recherches historiques (Brügger, 2009), ce dernier en vient à introduire la notion de **strates analytiques du Web**<sup>6</sup>.

Brügger suggère de construire un système d'analyse dynamique pour réajuster, à souhait, le périmètre d'une recherche portant sur le Web. L'observateur doit ainsi pouvoir passer d'un ensemble de sites, à une page unique, voire descendre jusqu'aux éléments constitutifs de cette dernière (un texte, une image, etc)<sup>7</sup>. Cette approche, notons-le, n'est pas confinée au Web archivé, elle peut très bien s'adapter au Web vivant. Brügger définit 5 niveaux d'analyses (présentés ci-dessous du plus englobant au plus précis):

1. le Web dans son entièreté
2. la sphère Web
3. le site Web
4. la page Web
5. l'élément Web

La Figure 5.2 donne à voir une illustration de l'agencement de ces strates. Le premier niveau englobe l'entièreté des sites du Web vivant. Il inclut également les éléments de back-end (base de données, code côté serveur, etc) et plus généralement l'ensemble de l'infrastructure physique du Web (serveurs, câbles réseaux, supports numériques, etc).

La sphère Web, inspirée des travaux de Foot et al. sur le volet numérique des campagnes électorales états-uniennes du début des années 2000 (Foot and Schneider, 2006), désigne un ensemble de sites Web sélectionnés par un chercheur. C'est une construction ad hoc motivée par une question de recherche donnée, une thématique précise.

<sup>6</sup> En anglais : *analytical Web strata*.

<sup>7</sup> "One can distinguish the following five analytical strata: the web as a whole; the web sphere; the individual website; the individual webpage; and an individual textual web element on a webpage, such as an image", (Brügger, 2009), p.19



Les acteurs Web regroupés au sein de ces sélections n'ont pas forcément conscience d'appartenir à un tel groupe. Par exemple, les réseaux de sites e-Diasporas (Section 2.4) peuvent être considérés comme des sphères Web. Sites et pages Web sont ensuite définis de manière égale à ce que nous proposons au Chapitre 4.

L'élément Web est, quant à lui, défini comme l'élément textuel minimal d'une page Web<sup>8</sup>. Ce peut être un ensemble de caractères écrits sur une page, des images fixes ou mobiles, ainsi que des sons. Brügger en revanche écarte de cette liste les menus, barres d'informations et autres éléments de navigations.

L'historien propose ensuite trois pistes d'analyse pour chaque éléments Web : 1) considérer le médium (l'écran, l'ordinateur, le support de lecture, etc) 2) considérer l'élément textuel seul 3) considérer un état hybride médium/texte où le code informatique derrière la page Web serait à la fois objet et support du message<sup>9</sup>. Cet état, propre au numérique (Finnemann, 1997), est explicité dans un texte antérieur (Brügger, 2002) comme la rencontre d'une matérialité matérielle (les ordinateurs constitués de pièces de plastique, de métal ou de verre) et d'une matérialité immatérielle (le code informatique<sup>10</sup>).

<sup>8</sup> "The Web element is the minimal textual element on a webpage", (Brügger, 2009), p.20.

<sup>9</sup> "the intermediate textual level that the codes of 0/1 and their syntax constitute, a level that is in itself a text, insofar as it is composed of letters and a syntax", (Brügger, 2009), p.9.

<sup>10</sup> "the energy-based binary alphabet", (Brügger, 2002), p.21.




Figure 5.2: Les 5 strates analytiques du Web, d'après (Brügger, 2009)

Le fragment Web pourra assez naturellement s'inscrire dans la continuité des strates analytiques du Web, se situant quelque part entre l'élément Web et la page Web. Mais s'il ne nous semble pas nécessaire de descendre à un tel niveau de différenciation entre matérialité et immatérialité du Web<sup>11</sup>, nous tenons tout de même à conserver la dif-

<sup>11</sup> Rappelons que le Web archivé n'est déjà plus le Web, qu'il n'est que l'enregistrement sur fichier de ses éléments de front-end (fichiers HTML et CSS). Back-end et supports physiques ne faisant pas l'objet d'un archivage.

férence entre un élément tel qu’affiché à l’écran depuis le navigateur et la portion de code informatique dont il est l’expression. Nous voulons par exemple pouvoir demander à un moteur d’exploration d’archive de retourner l’ensemble des pages contenant une balise HTML donnée tout autant qu’un mot clé dans un paragraphe. Le fragment Web traduira ainsi une portion de code informatique et son interprétation à l’écran.

### Dater une page archivée

Notre réflexion sur les différents niveaux d’analyse ne doit pas être menée que d’un point de vue purement structurel. Il serait également intéressant de discuter de la datation d’une page Web archivée pour tendre vers une plus grande précision historique. Comment bien dater une page Web et le contenu dont elle est le support ? Comment approcher le plus précisément possible de la date de création réelle d’un message posté sur un forum ?




Figure 5.3: Répartition des archives de *yabiladi.com* dans la WayBack Machine ([https://web.archive.org/web/\\*/www.yabiladi.com](https://web.archive.org/web/*/www.yabiladi.com))

Les archives Web sont les traces directes des crawlers en charge des collectages (Section 4.1). En base de données, rappelons-le, une page archivée est indexée par sa seule date de téléchargement (aussi appelée date d’archivage) sur laquelle s’appuient les moteurs d’exploration existants pour retourner les résultats d’une recherche (par exemple la WayBack Machine, Figure 5.3). En comparant deux versions d’une même page archivée, il est possible de déterminer une date de dernière modification (Section 4.2) et de l’intégrer à une échelle de datation (Table 4.1).

En introduisant le fragment Web, nous souhaitons améliorer la précision historique des contenus archivés. Ne pas se satisfaire des seules dates de téléchargement et de dernière modification. Pour se faire, nous nous donnons comme objectif de chercher à identifier la date d’édition de chaque fragment Web et de répercuter cette donnée sur la datation des pages Web associées.




Figure 5.4: Date de création (rouge) d’un post de forum sur *yabiladi.com*

Une page Web évolue (Section 3.2) dès que son contenu est édité par un tiers : humain ou robot. Par *édition*, nous entendons la création, la modification ou la suppression d’un élément d’une page. Comme les actes de modification et de suppression demandent, pour être datés (même approximativement), de comparer deux versions archivées d’une même page (Rocco et al., 2003; Nunes et al., 2007), leur détection semble de prime abord compliquée à intégrer à notre moteur d’exploration d’archives, ce dernier travaillant sur des pages uniques et non des séquences de versions successives.

La création d’un message ou d’un commentaire peut en revanche être plus facilement datée. Des indices sont souvent dispersés à même

la page (Figure 5.4), reste alors à les interpréter et à les formater avant indexation (De Jong et al., 2005; Kanhabua and Nørve, 2009). Si l'en-tête HTTP d'une page Web a été archivé, celui-ci peut nous renseigner sur une date de dernière modification qui ne dépende pas directement du crawler (Amitay et al., 2004). À défaut, la création d'un contenu donné sera rapportée à sa première apparition sur l'ensemble des versions archivées d'une même page (Jatowt et al., 2007), cette comparaison peut être affinée si des URIs ont été par ailleurs collectées<sup>12</sup> (Aturban et al., 2017). Notons enfin qu'il existe des stratégies de datation adaptées à la nature interdépendante de certains contenus archivés, comme un réseau de citation d'articles de blogs par exemple (Toyoda and Kitsuregawa, 2006; Spitz et al., 2018).

À partir de ce point, nous assumerons, pour simplifier, que la date d'édition d'un fragment Web équivaut à sa date de création. Par extension, il est alors possible de dire que la date de création de toute page Web est, au mieux, la plus ancienne date d'édition de l'ensemble de ses fragments. De là, nous pouvons proposer une mise à jour de l'échelle de datation introduite par la Table 4.1, telle que :

Niveau	Nature de la date	Validité historique
page	téléchargement	
page	dernière modification	
page	création	
fragment	édition	

<sup>12</sup> Le système Memento propose de voir une page archivée comme la concaténation de toutes les URIs qu'elle agrège. Cette vue est appelée TimeMaps (Van de Sompel et al., 2013) et peut être exploitée pour comparer les dates de certaines URIs d'images par exemple.

Table 5.1: Échelle (actualisée) de datation d'une page Web archivée

Tout fragment Web devra donc, dans la mesure du possible, être associé à une date d'édition. Dans le cas contraire, sa date sera rapportée à celle de la page à laquelle il est associé. Et si bien dater une page archivée participe de son émancipation vis à vis du crawler, cela donne, par la même occasion, corps aux acteurs qui l'ont fait vivre.

Un article de blog ne s'écrit pas de lui-même, il est le fruit du geste d'un auteur (unique ou collectif, humain ou robot) qui l'a mis en ligne. Derrière les dates d'édition des fragments Web, peuvent transparaître les gestes de divers auteurs : blogueurs, commentateurs ou contributeurs qui deviennent dès lors objets ou dimensions possibles d'une exploration d'archives Web<sup>13</sup>. Serait-il alors possible, comme le suggère l'historien J. Morsel, d'écrire une histoire *symptomale*<sup>14</sup> (Morsel, 2016) à partir de nos corpus d'archives Web ? Cela reviendrait à considérer que certains fragments Web se trouvent chargés de la présence latente d'un auteur, fossilisée sous la surface des pages archivées, prête à être questionnée. Cette nouvelle perspective d'exploration nous mènera

<sup>13</sup> Pour le philosophe V. Flusser les gestes sont des séries de mouvements significatifs dont le but est déchiffrable, ils "montrent la façon dont nous sommes au monde", (Flusser, 2014), p.319.

<sup>14</sup> Alors que la trace, telle que nous la décrivions jusqu'ici, suggère l'absence de l'agent qui l'a produite (elle s'en est détachée), le symptôme, selon Morsel, suppose la présence latente de l'agent, coprésent à ce dont il est le signe (Morsel, 2016)

à considérer, depuis les archives Web, le devenir de communautés d'utilisateurs ou de collectifs d'auteurs tel que nous l'illustrerons dans le Chapitre 6. Une nouvelle dimension d'analyse des archives s'offre donc à nous : l'exploration par acteur (auteur, contributeur, commentateur, etc).

Figure 5.5: Dimensions d'exploration des archives Web (ajout de l'acteur)

temps x site x page x lien x fragment x **acteur**

### *Désagréger pour changer de temporalité*

Il n'est pas simple de retrouver une date d'édition dans une page Web vivante ou archivée. Cela a déjà été proposé par plusieurs travaux. On peut partir sur des indices ou des comparaisons entre version. C'est compliqué oui mais les bénéfices en terme de précision historiques sont impressionnant, afin de l'illustrer nous allons procéder à une expérience dans laquelle nous allons rapidement extraire l'ensemble des dates de création de tous les postes de yabiladi. Tout au long de sa vie la structure du fichier HTML derrière le forum a peut évolué et les class de noeuds sont restée identiques. Nous allons donc faire une extraction spécifique à yabiladi forum et comparer pour chaque page sa première date d'édition vs sa date de download. Nous reprenons donc la répartition proposée au chapitre 4 à laquelle nous ajoutons en bleue la répartition des dates d'éditions.

La réaprtition est plus linéaire et ne relève pas de trous entre 2013 et 2014. Plus intéressant encore, en passant de la temporalité vue depuis le crawler à celle vue depuis le site ou le fragments on peut remonter jusqu'en 2003. Soit une année seulement après la création véritable de yabiladi.com. Un contenu archivé contient plus de mémoire que ce qu'il ne semble offrir de prime abord

Là est tout l'enjeu du chagement d'unité que nous proposons qui est en réalité un changement de temporalité.

De la même manière, dans ses derniers travaux historiographiques (Baschet, 2018), l'historien médiéviste J. Baschet à recourt à W. Benjamin pour réaffirmer la nécessité de rompre avec une vision unilinéaire de l'histoire. Il faut, selon lui, faire éclater la continuité de l'histoire pour en isoler des constellations afin de mieux saisir l'ensemble d'un mouvement historique.

Et il existe d'autres temporalités, comme le présente Husserl tmtc ou les indiens du chiapas. Bref le fragment web c'est un changement d'échelle spatial et temporel. Et voici maintenant le moment de vous le présenter.

## 5.2 Le fragment Web : définition

A partir de maintenant nous assumons la nécessité de trouver une nouvelle unité d'exploration des archives web baptisé fragment web, s'inscrivant dans la 5ème strate du web et émancé (autant que possible) de tout lien avec le crawler. Cette unité devra autant que possible être relié à une éditionnate pour éviter les crawl legacy et maximiser la précision historique.

Comme la forme de ces fragments sera toujours lié au contexte de l'exploration dans laquelle elle sera utilisée, et comme nous voulons que des sociologues ou des historiens puissent s'en saisir ( car un historien demandera toujours à connaître le contexte (cf le papier sur les archives là) la définition suivante sera générique à dessein. Une définition pratique et son extraction technique sera proposer dans la section suivante et ciblée pour la question des collectifs migrants etteinds.

### *Définition*

Considérant la page Web comme unité de consultation de base du Web, bâti sur des modalités d'écriture propre au support numérique et constatant que du point de vue de la perception humaine une page web est le résultat de l'agencement logique de fragments sémantiques distincts, alors :

le fragment est un sous ensemble cohérent ...

## 5.3 Scraping et méthodologie d'extraction

### *Extraire de l'information issue d'une page Web*

Le scraping c'est quoi ? Les méthode classique ( visuel vs le reste ) Nettoyer ou tout conserver ? Pourquoi scraper ? ( orienter business ? ) l'on parle de readability et de fathom...

### *Implémentation technique*

Là on parle de riveaine et de la fonction distance ... L'algo les différents filtres on dit qu'il y a plusieurs implémentations

### *Exemples et discussions*

là on donne qq exemples et on dit que en tant qu'ingé on avait cherché un truc qui fonctionnait tout le temps mais c'est pas possible

et un historien a besoin de vouloir resizer à volonté Là on parle de l'automatique vs le fait à la main avec le truc firefox Du coup dans la suite, le treshold de la fonction distance sera toujours testées avec le truc firefox

#### **5.4 Penser une exploration désagrégée**

*Atténuer les "crawl blindness"*

*Cohérence relative entre archives*

*Dédupliquer les corpus*

#### **5.5 Intégration à un moteur d'exploration**

*D'un schéma à un autre*

*Retour à la détection d'événements*

*S'éloigner des moteurs d'exploration*

## Chapitre 6

# | Explorations de Collectifs Migrants Éteints

Où l'on parle d'exploration de blogs, de forum et de moments

### 6.1 À la recherche de l'étonnement : l'analyse exploratoire de données

*De Tuckey à Fry*

Où l'on explique l'EDA de où ça vient

*Abduction, déduction, induction*

Où l'on introduit la philosophie générale de l'EDA et on peut faire un lien avec Ginsburg

*Méthodologie technique d'exploration*

Où l'on explique comment techniquement nous allons procéder en suivant plutôt Fry

### 6.2 Les traces d'une mutation numérique

*D'une communauté vibrante de blogs ...*

Là on raconte l'état des blogs en 2008

En revanche, une blogosphère dont les acteurs sont parfois à l'origine même de sa construction et de sa promotion<sup>1</sup> n'est pas strictement équivalente à une sphère Web. (Keren, 2006)

<sup>1</sup> De 2007 à 2011 la blogosphère marocaine a organisé ses propres *blog awards* pour récompenser, promouvoir et connecter ses acteurs. Voir [https://fr.wikipedia.org/wiki/Maroc\\_Web\\_Awards](https://fr.wikipedia.org/wiki/Maroc_Web_Awards)

*... à un collectif éteint*

Là on raconte l'état des blogs en 2018

*Définir l'espace d'exploration*

Là on explique la forme des fragments que l'on va chercher à retrouver

*Migration d'un territoire Web à un autre*

Là comprend que les blogs se sont déplacé vers Fb et Twitter

*Conserver son identité numérique*

Là on parle de la communauté des blogs

*Le Printemps Arabe vu comme un moment-clé*

Là on introduit le Printemps arabe marocain

### **6.3 Un soulèvement en ligne éphémère**

*Yabiladi.com : porte d'entrée sur la diaspora*

Là on explique ce qu'est Yabiladi

*La manifestation du 20 Février 2011*

Là on rappelle ce qu'est cet événement

*Définir l'espace d'exploration*

Là on explique la forme des fragments que l'on va chercher à étudier

*Voir un site évoluer*

Là on explique comment on va visualiser ces fragments



*Agréger les contributeurs*

Là on s'intéresse au graph des contributeurs

*De l'embrassement à l'évasion*

Là on regarde les clusters de Threads

**6.4 Les Moments Pivot du Web***Les limites de l'archivage du Web*

Les archives ne capturent pas le Web comme un environnement

*Les moments pivots du Web*

Un moment pivot c'est quoi ? Les geste et compagnie ainsi que la micro-histoire

*Temporalités d'analyse*

Là on se dit que l'exploration désagrégée c'est quand meme pas mal et que l'on peut étudier les archives autour de moments singuliers

*Repenser nos archives vis à vis des moments pivots*

Là on commence à parler de la suite, du web que l'on souhaite, de la neutralité et des défis à venir de l'archivage



## Chapitre 7

# | Au Delà Des Archives Web

### **7.1 Remettre l'humain au cœur des archives**

### **7.2 Fouiller les archives du Web profond**

voir el bouquin de mazanès p63

### **7.3 Les traces nativement numérique**

### **7.4 Vers une sociologie numérique des migrations**



# Ressources

## 8.1 References

References are placed alongside their citations as sidenotes, as well. This can be accomplished using the normal `\cite` command.<sup>1</sup>

The complete list of references may also be printed automatically by using the `\bibliography` command. (See the end of this document for an example.) If you do not want to print a bibliography at the end of your document, use the `\nobibliography` command in its place.

To enter multiple citations at one location,<sup>2</sup> you can provide a list of keys separated by commas and the same optional vertical offset argument: `\cite{Tufte2006,Tufte1990}`.

```
\cite[<offset>]{bibkey1,bibkey2,...}
```

<sup>1</sup> The first paragraph of this document includes a citation.

<sup>2</sup>; and

## 8.2 Figures and Tables

Images and graphics play an integral role in Tufte's work. In addition to the standard `figure` and `tabular` environments, this style provides special figure and table environments for full-width floats.

Full page-width figures and tables may be placed in `figure*` or `table*` environments. To place figures or tables in the margin, use the `marginfigure` or `marginfigure` environments as follows (see figure 8.1):

```
\begin{marginfigure}
\includegraphics{helix}
\caption{This is a margin figure.}
\label{fig:marginfig}
\end{marginfigure}
```

The `marginfigure` and `marginfigure` environments accept an optional parameter `<offset>` that adjusts the vertical position of the figure or table. See the “??” section above for examples. The specifications are:




Figure 8.1: This is a margin figure. The helix is defined by  $x = \cos(2\pi z)$ ,  $y = \sin(2\pi z)$ , and  $z = [0, 2.7]$ . The figure was drawn using Asymptote (<http://asymptote.sf.net/>).

```

\begin{marginfigure}[<offset>]
...
\end{marginfigure}

\begin{margintable}[<offset>]
...
\end{margintable}

```

Figure 8.2 is an example of the `figure*` environment and figure 8.3 is an example of the normal `figure` environment.





Figure 8.2: This graph shows  $y = \sin x$  from about  $x = [-10, 10]$ . Notice that this figure takes up the full page width.

Figure 8.3: Hilbert curves of various degrees  $n$ . Notice that this figure only takes up the main textblock width.



Chapitre 9

## | Conclusion





# | Bibliographie

- Abiteboul, S., Cobena, G., Masanes, J., and Sedrati, G. (2002). A first experience in archiving the French Web. In *International Conference on Theory and Practice of Digital Libraries*, pages 1–15. Springer.
- Adar, E., Teevan, J., Dumais, S. T., and Elsas, J. L. (2009). The web changes everything: understanding the dynamics of web content. In *Proceedings of the Second ACM International Conference on Web Search and Data Mining*, pages 282–291. ACM.
- AlNoamany, Y. A., Weigle, M. C., and Nelson, M. L. (2013). Access patterns for robots and humans in web archives. In *Proceedings of the 13th ACM/IEEE-CS joint conference on Digital libraries*, pages 339–348. ACM.
- Amitay, E., Carmel, D., Herscovici, M., Lempel, R., and Soffer, A. (2004). Trend detection through temporal link analysis. *Journal of the Association for Information Science and Technology*, 55(14):1270–1281.
- Arvidson, A., Persson, K., and Mannerheim, J. (2000). The Kulturarw3 Project–The Royal Swedish Web Archiw3e–An Example of "Complete" Collection of Web Pages.
- Aturban, M., Nelson, M. L., and Weigle, M. C. (2017). Difficulties of Timestamping Archived Web Pages. *arXiv preprint arXiv:1712.03140*.
- Baeza-Yates, R., Castillo, C., Marin, M., and Rodriguez, A. (2005). Crawling a country: better strategies than breadth-first for web page ordering. In *Special interest tracks and posters of the 14th international conference on World Wide Web*, pages 864–872. ACM.
- Baschet, J. (2018). *Défaire la tyrannie du présent: Temporalités émergentes et futurs inédits*. L'horizon des possibles. Editions La Découverte.
- Ben-David, A. and Amram, A. (2018). The Internet Archive and the socio-technical construction of historical facts. *Internet Histories*, pages 1–23.
- Bon, F. (2014). *Après le livre*. Tiers Livre Éditeur.

- Borges, J. (1974). *Fictions*. Collection Folio. Editions Gallimard.
- Borgman, C. L. (2000). Digital libraries and the continuum of scholarly communication. *Journal of documentation*, 56(4):412–430.
- Boudrez, F. and Van den Eynde, S. (2002). Archiving websites. *State Archives of Antwerp, Antwerp-Leuven*.
- Brügger, N. (2002). Does the materiality of the Internet matter. *The Internet and society*, pages 13–22.
- Brügger, N. (2009). Website history and the website as an object of study. *New Media & Society*, 11(1-2):115–132.
- Canfora, L. (1990). *The Vanished Library: A Wonder of the Ancient World*, volume 7. Univ of California Press.
- Castillo, C., Marin, M., Rodriguez, A., and Baeza-Yates, R. (2004). Scheduling algorithms for Web crawling. In *WebMedia and LA-Web, 2004. Proceedings*, pages 10–17. IEEE.
- Chakravarthy, S., Jacob, J., Pandrangi, N., and Sanka, A. (2002). Web-vigil: An approach to just-in-time information propagation in large network-centric environments. In *Second International Workshop on Web Dynamics*.
- Chawathe, S. S. and Garcia-Molina, H. (1997). Meaningful change detection in structured data. In *ACM SIGMOD Record*, volume 26, pages 26–37. ACM.
- Cho, J. and Garcia-Molina, H. (1999). The evolution of the web and implications for an incremental crawler. Technical report, Stanford.
- Cho, J., Garcia-Molina, H., and Page, L. (1998). Efficient crawling through URL ordering. *Computer Networks and ISDN Systems*, 30(1-7):161–172.
- Coriat, B. and others (2015). *Le retour des communs: & la crise de l'idéologie propriétaire*. Éditions Les Liens qui libèrent.
- De Jong, F., Rode, H., and Hiemstra, D. (2005). Temporal language models for the disclosure of historical text. In *Humanities, computers and cultural heritage: Proceedings of the XVIth International Conference of the Association for History and Computing (AHC 2005)*, pages 161–168.
- De Kosnik, A. (2016). *Rogue archives: Digital cultural memory and media fandom*. MIT Press.
- Denev, D., Mazeika, A., Spaniol, M., and Weikum, G. (2009). SHARC: framework for quality-conscious web archiving. *Proceedings of the VLDB Endowment*, 2(1):586–597.

- Derrida, J. (1995). *Mal d'archive*. Paris, Galilee, page 371.
- Derrida, J. (2014). *Trace et archive, image et art*. Collection Collège iconique. INA.
- Douglis, F., Ball, T., Chen, Y.-F., and Koutsofios, E. (1998). The AT&T Internet Difference Engine: Tracking and viewing changes on the web. *World Wide Web*, 1(1):27–44.
- Dougnac, M.-T. and Guilbaud, M. (1960). Le dépôt légal: son sens et son évolution.
- Dugeon, T. (2005). A technical approach for the French web legal deposit. In *5th International Web Archiving Workshop (IWAW05)*, Vienna, Austria. Citeseer.
- Dumais, S., Cutrell, E., Cadiz, J. J., Jancke, G., Sarin, R., and Robbins, D. C. (2016). Stuff I've seen: a system for personal information retrieval and re-use. In *ACM SIGIR Forum*, volume 49, pages 28–35. ACM.
- Febvre, L. and Martin, H.-J. (2013). *L'apparition du livre*. Albin Michel.
- Fetterly, D., Manasse, M., Najork, M., and Wiener, J. (2003). A large-scale study of the evolution of web pages. In *Proceedings of the 12th international conference on World Wide Web*, pages 669–678. ACM.
- Finnemann, N. O. (1997). Modernity modernised: The cultural impact of computerisation.
- Fitch, K. (2003). Web site archiving-an approach to recording every materially different response produced by a website.
- Flusser, V. (2014). *Les gestes*. Cahiers Du Midi. Al Dante Eds.
- Foot, K. and Schneider, S. M. (2006). *Web campaigning (acting with technology)*. The MIT Press.
- Gomes, D., Miranda, J., and Costa, M. (2011). A survey on web archiving initiatives. In *International Conference on Theory and Practice of Digital Libraries*, pages 408–420. Springer.
- Gomes, D., Nogueira, A., Miranda, J., and Costa, M. (2009). Introducing the Portuguese web archive initiative. In *8th International Web Archiving Workshop*. Springer.
- Hallgrinsson, B. and Bang, S. (2003). Nordic web archive. In *Proceedings of the 3rd Workshop on Web Archives in conjunction with the 7th European Conference on Research and Advanced Technologies for Digital Libraries (ECDL 2003)*, pages 37–48.

- Hölscher, C. and Strube, G. (2000). Web search behavior of Internet experts and newbies. *Computer networks*, 33(1-6):337–346.
- Jatowt, A., Kawai, Y., and Tanaka, K. (2007). Detecting age of page content. In *Proceedings of the 9th annual ACM international workshop on Web information and data management*, pages 137–144. ACM.
- Kahle, B. (1997). Preserving the Internet. *Scientific American*, 276:82–83.
- Kanhabua, N. and Nørøv\ a ag, K. (2009). Using temporal language models for document dating. In *Joint European Conference on Machine Learning and Knowledge Discovery in Databases*, pages 738–741. Springer.
- Keren, M. (2006). *Blogosphere: The new political arena*. Lexington Books.
- Ketelaar, E. (2006). (Dé) Construire l’archive. *Matériaux pour l’histoire de notre temps*, (2):65–70.
- Khoury, I., El-Mawas, R. M., El-Rawas, O., Mounayar, E. F., and Artail, H. (2007). An Efficient Web Page Change Detection System Based on an Optimized Hungarian Algorithm. *IEEE Transactions on Knowledge and Data Engineering*, 19(5):599–613.
- Kimpton, M. and Ubois, J. (2006). Year-by-year: from an archive of the Internet to an archive on the Internet. In *Web archiving*, pages 201–212. Springer.
- Koehler, W. (1999). An analysis of web page and web site constancy and permanence. *Journal of the Association for Information Science and Technology*, 50(2):162.
- Koehler, W. and others (2004). A longitudinal study of Web pages continued: a consideration of document persistence. *Information Research*, 9(2):9–2.
- Lawrence, S. and Giles, C. L. (2000). Accessibility of information on the web. *intelligence*, 11(1):32–39.
- Leclerc, E. (2012). Le cyberspace de la diaspora indienne.
- Leroi-Gourham, A. (1984). *L’Art des cavernes: Atlas des grottes ornées paléolithiques françaises (Atlas archéologiques de la France) (French Edition)*. Impr. nationale.
- Leroi-Gourhan, A. (1964). *Le geste et la parole*. Albin Michel.
- Lim, S.-J. and Ng, Y.-K. (2001). An automated change-detection algorithm for HTML documents based on semantic hierarchies. In *Data Engineering, 2001. Proceedings. 17th International Conference on*, pages 303–312. IEEE.

- Liu, L., Pu, C., and Tang, W. (2000). WebCQ-detecting and delivering information changes on the web. In *Proceedings of the ninth international conference on Information and knowledge management*, pages 512–519. ACM.
- Masanès, J. (2006). Web archiving: issues and methods. In *Web Archiving*, pages 1–53. Springer.
- McDonnell, J. P., Koehler Jr, W. C., and Carroll, B. C. (1999). Cataloging Challenges in an Area Studies Virtual Library Catalog (ASVLC) Results of a Case Study. *Journal of Internet Cataloging*, 2(2):15–42.
- Mitchell, R. (2015). *Web scraping with Python: collecting data from the modern web*. " O'Reilly Media, Inc."
- Mohr, G., Stack, M., Ranitovic, I., Avery, D., and Kimpton, M. (2004). An Introduction to Heritrix An open source archival quality web crawler. In *In IAWW'04, 4th International Web Archiving Workshop*. Citeseer.
- Morsel, J. (2016). Traces? Quelles traces? Réflexions pour une histoire non passéiste. *Revue historique*, (4):813–868.
- Nunes, S., Ribeiro, C., and David, G. (2007). Using neighbors to date web documents. In *Proceedings of the 9th annual ACM international workshop on Web information and data management*, pages 129–136. ACM.
- Oita, M. and Senellart, P. (2010). Archiving data objects using Web feeds. In *International Workshop on Web Archiving*.
- Page, L., Brin, S., Motwani, R., and Winograd, T. (1999). The PageRank Citation Ranking: Bringing Order to the Web. Technical Report 1999-66, Stanford InfoLab.
- Pandey, S. and Olston, C. (2005). User-centric web crawling. In *Proceedings of the 14th international conference on World Wide Web*, pages 401–411. ACM.
- Pant, G., Srinivasan, P., and Menczer, F. (2004). Crawling the web. In *Web Dynamics*, pages 153–177. Springer.
- Pop, R., Vasile, G., and Masanes, J. (2010). Archiving web video. In *International Web Archiving Workshop IAWW 2010*.
- Risse, T., Demidova, E., Dietze, S., Peters, W., Papailiou, N., Doka, K., Stavarakas, Y., Plachouras, V., Senellart, P., Carpentier, F., and others (2014). The ARCOMEM architecture for social-and semantic-driven web archiving. *future internet*, 6(4):688–716.

- Rocco, D., Buttler, D., and Liu, L. (2003). Page digest for large-scale web services. In *E-Commerce, 2003. CEC 2003. IEEE International Conference on*, pages 381–390. IEEE.
- Saad, M. B., Pehlivan, Z., and Gançarski, S. (2011). Coherence-oriented crawling and navigation using patterns for web archives. In *International Conference on Theory and Practice of Digital Libraries*, pages 421–433. Springer.
- Schafer, V. and Thierry, B. G. (2016). The “Web of pros” in the 1990s: The professional acclimation of the World Wide Web in France. *New Media & Society*, 18(7):1143–1158.
- Schneider, S. M., Foot, K., Kimpton, M., and Jones, G. (2003). Building thematic web collections: challenges and experiences from the September 11 Web Archive and the Election 2002 Web Archive. *Digital Libraries, ECDL*, pages 77–94.
- Spaniol, M. and Weikum, G. (2012). Tracking entities in web archives: the LAWA project. In *Proceedings of the 21st International Conference on World Wide Web*, pages 287–290. ACM.
- Spinellis, D. (2003). The decay and failures of web references. *Communications of the ACM*, 46(1):71–77.
- Spitz, A., Strötgen, J., and Gertz, M. (2018). Predicting Document Creation Times in News Citation Networks. In *Companion of the The Web Conference 2018 on The Web Conference 2018*, pages 1731–1736. International World Wide Web Conferences Steering Committee.
- Stiegler, B. (1991). *Etat de la mémoire et mémoire de l’Etat*, volume 1.
- Stiegler, B. (1998). Leroi-Gourhan: l’inorganique organisé. *Les Cahiers de médiologie*, (2):187–194.
- Toyoda, M. and Kitsuregawa, M. (2006). What’s really new on the web?: identifying new pages from a series of unstable web snapshots. In *Proceedings of the 15th international conference on World Wide Web*, pages 233–241. ACM.
- UNESCO (2003). Charter on the Preservation of Digital Heritage.
- Van de Sompel, H., Nelson, M., and Sanderson, R. (2013). HTTP framework for time-based access to resource states–Memento. Technical report.
- Voerman, G., Keyzer, A., Den Hollander, F., and Druiven, H. (2002). Archiving the Web: Political party Web sites in the Netherlands. *European Political Science*, 2(1):68–75.

Yadav, D., Sharma, A. K., and Gupta, J. P. (2007). Change Detection in Web Pages. pages 265–270. IEEE.